

带测量误差的高维线性模型的变量选择和
参数估计

Variable selection and parameter estimation
for high-dimensional linear model with
measurement error

一级学科： 数学

研究方向： 概率论与数理统计

作者姓名： 陈聪

指导教师： 关静 教授

答辩日期	2023 年 5 月 26 日		
答辩委员会	姓名	职称	工作单位
主席	王萍	教授	天津大学
委员	谢中华	副教授	天津科技大学
	孙晓晨	副教授	天津大学

天津大学数学学院
二〇二三年六月

摘 要

随着高维数据的常态化,在医学、金融等领域有着广泛应用的线性模型逐渐演变为高维线性模型。在实际研究中,数据往往存在着测量误差的问题,如果忽略此问题,将导致模型的参数估计结果产生偏差。因此,越来越多的研究者对上述问题进行了深入研究。

本文主要研究带测量误差的高维线性模型的变量选择和参数估计。首先,建立了带 Classical 可加测量误差的高维线性模型。其次,采用 Lasso 惩罚最小二乘法和无偏估计量构建了目标函数,由于其通常是非凸的,因此提出了基于 F 范数寻找最近正定矩阵的方法,即将非凸函数转换为凸函数;此外还将 SCAD 惩罚函数与此方法进行了结合。然后,使用坐标下降法对目标函数进行求解,并推导了相应参数估计的理论性质。最后,对上述方法进行了 Monte Carlo 模拟,结果表明与 SCAD 惩罚函数结合的方法有着更优的性能,同时用此方法分析了 Boston housing 数据集和利尿剂抵抗数据集,说明了方法的实用性和有效性。

由于 Classical 测量误差的正态性假设会限制模型的应用,因此考虑了扭曲测量误差,并对高维线性模型的变量选择和参数估计进行了研究。首先,利用核密度估计恢复了不能被直接观测得到的变量。其次,分别采用 Lasso 和 SCAD 惩罚最小二乘法构建了目标函数,并借助坐标下降法进行求解。最后,对上述方法进行了 Monte Carlo 模拟,结果表明两种方法能够较好地处理扭曲测量误差,但与 SCAD 惩罚函数结合的方法的性能更优,同时将此方法应用在 Boston housing 数据集中,说明了方法的实用性和有效性。

关键词: 测量误差, 高维线性模型, Lasso, SCAD, 坐标下降法, Monte Carlo 算法

ABSTRACT

As high-dimensional data becomes increasingly common, linear model, which is widely used in fields such as medicine and finance, has evolved into high-dimensional linear model. In practical, data often contains issues such as measurement error, and if this problem is ignored, the estimation results will have a large deviation. Consequently, an increasing number of researchers have conducted in-depth investigations into this issue.

This paper primarily studies variable selection and parameter estimation in high-dimensional linear model with measurement error. Firstly, high-dimensional linear model with Classical additive measurement error is established. Secondly, the Lasso penalty least squares method and unbiased surrogates are employed to construct the objective function, which is typically non-convex. To address this, a method for finding the nearest positive definite matrix based on the F norm is proposed, transforming the non-convex objective function into a convex one. Furthermore, the SCAD penalty function is integrated into this method. Then, the coordinate descent is utilized to solve the objective functions, and the theoretical properties of the corresponding parameter estimates are derived. Finally, Monte Carlo simulations are carried out for the proposed methods, demonstrating that the method incorporating the SCAD penalty function performs better. This method is also applied to the Boston housing dataset and the diuretic resistance dataset, illustrating its effectiveness and practicality.

Given the limitations imposed by the assumption of normality in Classical measurement error, this study considers distorted measurement error and investigates variable selection and parameter estimation in high-dimensional linear model. Initially, the kernel density estimation method is used to recover the variables that cannot be directly observed. Subsequently, Lasso and SCAD penalty least squares methods are utilized to construct the objective function respectively, and the objective functions are solved using the coordinate descent. Eventually, Monte Carlo simulations of the proposed methods are performed, and the results demonstrate that the two methods can effectively handle distortion measurement error. However, the method incorporating the SCAD penalty function exhibits superior performance. This method is also applied to the Boston housing dataset, illustrating its effectiveness and practicality.

KEY WORDS: Measurement error, High-dimensional linear model, Lasso, SCAD, Coordinate descent method, Monte Carlo algorithm

目 录

第 1 章 绪论.....	1
1.1 选题背景.....	1
1.2 研究现状.....	2
1.2.1 测量误差.....	2
1.2.2 变量选择.....	3
1.2.3 带测量误差的高维线性模型的理论发展	3
1.3 文章结构.....	4
1.4 主要创新点.....	5
第 2 章 线性回归模型	7
2.1 多元线性回归模型.....	7
2.2 高维线性回归模型.....	8
2.3 经典线性回归模型的基本假设	8
第 3 章 测量误差模型	9
3.1 Classical 测量误差	9
3.1.1 Classical 测量误差对线性回归模型参数估计的影响	10
3.1.2 参数估计方法.....	11
3.2 扭曲测量误差.....	12
3.2.1 扭曲测量误差的影响.....	12
3.2.2 参数估计方法.....	12
第 4 章 带 Classical 可加测量误差的高维线性模型的变量选择和参数估计	15
4.1 符号与模型.....	15
4.2 参数估计.....	16
4.2.1 Lasso 惩罚最小二乘法	16
4.2.2 SCAD 惩罚最小二乘法	18
4.2.3 调优参数的选择.....	20
4.3 理论性质.....	21
4.4 Monte Carlo 数值模拟	23
4.5 实例应用.....	27
4.5.1 Boston housing 数据集.....	27
4.5.2 利尿剂抵抗数据集.....	27
4.6 定理证明.....	30
4.6.1 相关引理.....	30
4.6.2 相关证明.....	31

第 5 章 带可加扭曲测量误差的高维线性模型的变量选择和参数估计	39
5.1 符号与模型	39
5.2 参数估计	40
5.2.1 核密度估计法	40
5.2.2 惩罚最小二乘法	40
5.2.3 窗宽及调优参数的选择	41
5.3 重采样方法	42
5.4 Monte Carlo 数值模拟	42
5.5 实例分析	43
第 6 章 总结与展望	47
6.1 总结	47
6.2 展望	48
参考文献	49

第1章 绪论

1.1 选题背景

回归分析是统计学研究中非常成熟且重要的一个理论，是一种确定两个或两个以上变量间相互依赖的定量关系的统计分析方法。其中，线性回归在回归分析中占据着基础且重要的地位，已被广泛地应用到诸多领域，如生物统计学、医学、金融学、经济学、流行病学和公共卫生学等，这主要是因为线性依赖于其未知参数的模型比非线性更加容易拟合，并且产生的估计所具有的统计特性也更加容易确定。

在回归分析中，为了便于研究模型的相关特性，往往会默认模型中的变量是真实观测的，是不带任何误差的值。然而在实际研究中，由于测量方法的不当、测量条件的限制，以及测量仪器本身校正不完善等原因，都可能导致测量结果是带有误差的。同时，也存在着某些变量本身就是不可观测的，只能使用替代变量的观测数据去代替的情况，这更加说明了测量误差的存在是无法避免的。例如，在医学中研究血糖含量与糖尿病患病率之间的关系时，由于测量仪器的限制常常导致血糖含量的测量值存在测量误差。如果在进行回归分析时，忽略测量误差的存在，将会导致模型的参数估计结果是有偏的，从而降低模型的预测精度，甚至得到有偏差的结论。

此外，随着科学技术的不断发展和完善，数据的采集工作也变得越发简单，进而在统计学、医学和经济学等诸多领域内，所收集到的数据越来越多，也越来越呈现为高维数据，其主要特征是指协变量的维数大于样本量。例如人类的基因维数很高，但是导致某类疾病发生的基因却只有少数几个或几十个。众所周知，对于一个模型而言，如果丢失重要变量将会导致模型的估计产生巨大的偏差，但如果包含冗余变量又会增加模型的复杂度，降低模型的有效估计。因此，关于高维数据的处理工作备受统计研究者的关注，也逐渐成为近年来各个领域的研究热点。

综上，为了扩展线性模型在高维数据中的应用，深入研究数据带测量误差的问题是十分有意义的。

1.2 研究现状

1.2.1 测量误差

在实际生活中, 由于外界因素、观测者的技术水平和仪器本身校正不完善等原因, 都有可能导致变量的观测值是有误差的, 即变量带有测量误差。例如, MacMahon 等人^[1] 在研究血压对中风和冠心病影响的分析中, 考虑了血压测量时存在测量误差; Lin 和 Carrol^[2] 以及 Liang 等人^[3] 对 AIDS 的研究中, 考虑了 CD4 细胞测量时存在测量误差; 其他著名例子还包括心血管疾病研究中的胆固醇水平。众所周知, 忽略测量误差, 简单地用测量的变量去替换真实的变量将导致有偏差的估计, 进而得到有偏差的结论^[4]。

有关测量误差的研究最早可追溯于 Adcock 的研究^{[5][6]}, 对两个含有误差的变量的线性模型进行了研究, 并在误差方差之比已知的条件下对模型的未知参数进行了估计。但在此之后, 由于种种原因的存在, 导致与测量误差相关的理论研究发展缓慢。直到二十世纪七八十年代, 测量误差模型才逐渐受到统计研究者的重视, 并开始迅速发展, 第一次系统地介绍测量误差模型是在 Kendall 和 Stuart^[7] 的著作中。随后, Fuller 将 1980 年之前有关测量误差的相关理论进行了总结, 并在其著作^[8] 中详细地论述了不同假设下的测量误差模型的参数估计方法。

以往的测量误差主要是指 Fuller 一书中所提及的, 一般划分为三类: Classical 测量误差、Berkson 测量误差、Classical 和 Berkson 混合测量误差。其中与 Classical 测量误差对应的 Classical 测量误差模型是应用最多和最为常见的。目前有关 Classical 测量误差的相关理论已经非常成熟, 也提出了很多解决此类问题的研究方法。例如, Brown^[9] 提出了正交回归法; Cook 和 Stefanski^[10] 提出了模拟外推法 (SIMEX), 该方法因其对功能测量误差模型和结构测量误差模型的普遍适用性而颇受欢迎, 但它是计算密集型的; Wang 等人^[11] 提出了一个简单、快速、易于实现的方法—回归校正法; Thoresen 和 Laake^[12] 提出了因子得分法, 该方法是基于从因子分析中提取的因子得分理论; 以及工具变量法^{[13][14]} 等。对于另外两类测量误差, 也有许多统计研究者进行了相关研究。例如, Küchenhoff 等人^[15] 研究了 Berkson 测量误差对 Cox 回归模型的参数估计的影响; Yin 等人^[16] 对非参数 Classical 和 Berkson 混合测量误差回归模型进行了研究, 提出了一种基于 Tikhonov 正则化的估计方法; Tapsoba 等人^[17] 对带有 Classical 和 Berkson 测量误差的广义线性模型进行了研究, 提出了一种预估计方程式的方法。

然而, 大多数提出的研究方法依赖于测量误差的正态性假设, 这会限制各个模型方法的应用。近年来, 扭曲测量误差由于不会对误差分布做出假设, 开始受到统计研究者的关注, 与之相关的理论也开始逐渐发展。例如, Zhang 等人^[18] 在

可加扭曲测量误差存在的情况下,对变量之间的相关系数的估计进行了研究,并提出了两种估计器;Feng 等人^[19]对含有可加扭曲测量误差的线性模型进行了研究,并提出了两个检验统计量来检验线性回归模型的有效性;Zhang^[20]对含有可加扭曲测量误差的部分线性回归模型的估计和假设检验进行了研究,推导了估计量的渐近性质;Zhang 等人^[21]研究了带乘法扭曲测量误差的模态线性回归模型,使用了四种校准程序估计模型参数,并推导了相应的渐近性质。

1.2.2 变量选择

关于模型变量选择的方法,较为传统的有 AIC 准则、BIC 准则和 Cp 准则等。然而,这些方法的计算量较为庞大,且相关理论较难研究。特别是在大数据时代,数据越来越呈现为高维数据,如果仍然使用这些方法,将会很难得到有效的变量且计算成本非常昂贵。因此,为了改善在高维数据下的变量选择方法,越来越多的统计研究者开始关注此问题,并提出了一系列其它的变量选择方法。正则化方法由于具有同时进行变量选择和参数估计的特性而颇受欢迎,其形式主要表现为损失函数与惩罚函数的结合,即

$$\min\left\{\sum_{i=1}^n l(f(x_i, y_i)) + p_{\lambda}(\cdot)\right\}, \quad (1-1)$$

其中, $l(\cdot)$ 为损失函数, $\{x_i, y_i\}_{i=1}^n$ 为可观测的数据, $p_{\lambda}(\cdot)$ 为惩罚函数。

对于正则化方法的研究主要体现在惩罚函数上,现有相当多的统计研究者已经针对不同的情况提出了不同的惩罚函数。Lasso^[22]最初由 Tibshirani 提出,该方法在处理模型变量个数较多时有着明显的优势且方法较为简单,但是在统计理论上存在着不足,即由 Lasso 方法得到的参数估计不满足相合性。为弥补此缺陷, Zou 提出了 Adaptive Lasso^[23], Fan 和 Li 提出了 SCAD 惩罚函数^[24]以及 Zhang 提出了 MCP 惩罚函数^[25]等。除此之外, Lasso 方法只能选择单个的变量,对于一般具有组结构的变量选择,此方法就不再适用,而在实际生活中,变量往往是以组的形式存在的。因此, Yuan 和 Li^[26]提出了 Group Lasso 方法,改进了 Lasso 方法无法处理具有组结构数据的缺陷。关于正则化的其它方法还有 Zou 和 Hastie 提出的弹性网^[27]以及 Candes 等人提出的 Dantzig 选择器^[28]等,有关正则化方法更详细的论述可以在 Fan 和 Lv^[29]中找到。

1.2.3 带测量误差的高维线性模型的理论发展

如今处于大数据时代,高维数据越来越常态化,在回归分析中占据着基础且重要地位的线性模型也逐渐演变为高维线性模型。同时,由于测量不准确或无法测量等原因,在高维线性模型中引入测量误差也是很自然的事。

对于带测量误差的高维线性模型的研究,其难点主要在于两点:一是如何进

行变量选择,使得模型重要变量能够被正确选择,从而提高模型的有效估计以及降低模型的复杂度;二是如何克服测量误差所带来的影响。对此,有不少的统计研究者进行了相关研究,并有针对性地提出了解决此类问题的方法。例如, Sørensen 等人^[30]研究了测量误差对 Lasso 惩罚线性回归的影响,提出了一种简单的修正测量误差的方法,并推广到了广义线性模型上; Rosenbaum 和 Tsybakov^[31]提出了 MU 选择器,这是对 Dantzig 选择器的一种改进,可以用来处理测量误差和缺失数据。随后, Rosenbaum 和 Tsybakov^[32]又提出了一种改进的 MU 选择器; Loh 和 Wainwright^[33]研究了具有 Lasso 正则化的广义 M 估计量,其中的特殊情况就包括对测量误差或缺失数据的修正; Datta 和 Zou^[34]提出了 CoCoLasso 方法,它将非凸方法转换为了凸方法,可以处理一类有损坏的数据; Tao 等人^[35]提出了一个校准零范数 LS 估计器,并使用多阶段凸松弛方法来计算这个估计量。

然而,上述研究中的测量误差大多服从正态分布,该假设会限制高维线性模型的应用。因此,有统计研究者在对高维线性模型的研究中,考虑了一般化的测量误差,即扭曲测量误差,这极大地拓展了模型的应用,如 Li 等人^[36]采用了 SCAD 惩罚最小二乘法对高维协变量调整线性回归模型同时进行变量选择和参数估计,并提出了一个 BIC 准则来选择调优参数。

据我们所知,在高维线性模型中考虑变量存在测量误差的问题还可以进一步研究。例如,对于 Classical 可加测量误差,可以对相关模型方法进行优化,降低计算成本;而对于可加扭曲测量误差,有关此类问题的研究还比较少。因此,为了完善和丰富高维线性模型的相关理论,我们有必要针对上述问题进行深入研究。

1.3 文章结构

第一章给出了本文的选题背景以及相关内容的研究现状,包括测量误差、变量选择以及带测量误差的高维线性模型的理论发展。第二章简单介绍了多元线性回归模型、高维线性回归模型以及经典线性回归模型的基本假设。第三章先后介绍了 Classical 测量误差和扭曲测量误差,并分别阐述了这两种测量误差对模型参数估计的影响,以及处理这两类测量误差的常用方法,如工具变量法和核密度估计法。第四章研究了带 Classical 可加测量误差的高维线性模型的变量选择和参数估计。首先,在高维线性模型下考虑 Classical 可加测量误差,并建立了相关模型。其次,简单介绍了 Lasso 方法及其优缺点,并采用 Lasso 惩罚最小二乘法和无偏估计量构建了求解模型参数的目标函数,由于该目标函数通常是非凸函数,因此提出了基于 F 范数寻找最近正定矩阵的方法,即将非凸目标函数转换为凸函数;此外,还介绍了 SCAD 惩罚函数,以及与 Lasso 的相同与不同之

处,并将 SCAD 惩罚函数与此方法进行了结合。接下来,使用坐标下降法分别对这两种方法的目标函数进行求解,并推导了相应参数估计的理论性质。最后,对上述方法进行了 Monte Carlo 数值模拟,并将与 SCAD 惩罚函数结合的方法应用在 Boston housing 数据集和利尿剂抵抗数据集中。第五章研究了带可加扭曲测量误差的高维线性模型的变量选择和参数估计,扩展了模型的应用范围。首先,使用核密度估计法恢复了被扭曲的预测变量和响应变量,并基于恢复后的数据集,采用 Lasso 惩罚最小二乘法构建求解模型参数的目标函数;此外还将 SCAD 惩罚函数与该方法进行了结合。其次,使用坐标下降法对目标函数进行了求解。最后,给出了 Monte Carlo 数值模拟,并将与 SCAD 惩罚函数结合的方法应用在了 Boston housing 数据实例分析中。第六章对全文的工作进行了总结并提出了未来展望。

1.4 主要创新点

(1) 高维线性模型在高维数据研究领域十分常见,并且变量带 Classical 测量误差以及考虑变量选择的问题也是经常出现的。目前,解决此类问题的相关研究方法存在着计算成本昂贵、计算时长较长等不足。本文针对该问题,采用 Lasso 惩罚最小二乘法,并结合无偏估计量构建了求解模型参数的目标函数,由于该目标函数通常是非凸函数,因此提出了基于 F 范数寻找最近正定矩阵的方法,即将非凸目标函数转换为凸函数。此外还将 SCAD 惩罚函数与此方法进行了结合。在一般条件下,分别证明了这两种方法得到的参数估计的理论性质。提出的方法易于计算,且性能良好。最后本文给出了模拟与实例应用。

(2) 有关解决 Classical 测量误差的相关方法依赖于测量误差的正态性假设,这会极大地限制模型方法的应用,而扭曲测量误差的使用则可以改善这一局限。此外,带可加扭曲测量误差的高维线性模型的变量选择和参数估计问题的相关研究还比较少。本文针对该问题,使用核密度估计法恢复了不可观测的预测变量和响应变量,并基于此数据,采用 Lasso 惩罚最小二乘法构建求解模型参数的目标函数;此外还将 SCAD 惩罚函数与该方法进行了结合。最后本文给出了模拟和实例应用。

第2章 线性回归模型

线性回归模型是统计学中的经典模型,广泛应用于医学、经济学和金融等领域。同时,也可以将非线性进行“线性化”,从而达到降低模型复杂度的效果,如对幂函数取对数,可将非线性的模型转化为线性的。在非高维数据中,根据协变量的个数可划分为一元和多元线性回归模型。在刻画数据以及建立变量之间的关系时容易发现因变量的变化是受到许多因素的影响,而非单一的。因此,为了信息的全面性以及模型的准确性,绝大多数情况需要对数据建立多元线性回归模型。在高维数据中,就需要建立高维线性回归模型。

2.1 多元线性回归模型

多元线性回归模型是指用两个或两个以上的预测变量来解释响应变量的一种模型,其一般形式如下:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_j X_j + \varepsilon, \quad (2-1)$$

其中, β_0 为常数项, $\beta_1, \beta_2, \dots, \beta_j$ 为回归系数, Y 为响应变量, $X_1, X_2, \dots, X_j$ 为预测变量, ε 为随机误差项。

如果对响应变量和预测变量进行了 n 次观测,得到 n 组观测值 $\{Y_i, X_{i1}, X_{i2}, \dots, X_{ij}, i = 1, \dots, n\}$,那么它们之间的关系可以用如下公式进行刻画:

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \cdots + \beta_j X_{ij} + \varepsilon_i. \quad (2-2)$$

引入矩阵符号,记

$$Y = \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix}, X = \begin{bmatrix} 1 & X_{11} & \cdots & X_{1j} \\ 1 & X_{21} & \cdots & X_{2j} \\ \vdots & \vdots & & \vdots \\ 1 & X_{n1} & \cdots & X_{nj} \end{bmatrix}, \beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_j \end{bmatrix}, \varepsilon = \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix},$$

则模型 (2-2) 可以写成如下形式:

$$Y = X\beta + \varepsilon, \quad (2-3)$$

其中, Y 是 $n \times 1$ 维响应变量, X 是 $n \times (j+1)$ 维预测变量矩阵, ε 为随机误差项, β 为 $(j+1) \times 1$ 维未知参数向量。

2.2 高维线性回归模型

经典的线性回归模型考虑的是预测变量的数量要小于样本量，然而处于大数据时代，高维数据越来越常态化，相应的线性回归模型也逐渐演变为高维线性回归模型。典型的高维线性模型假设可用预测变量的数量 (p_n) 大于样本量 (n)，尽管相关预测变量的真实数量 (s) 远小于 n 。本文所使用的高维线性模型不考虑截距项，若存在截距项，只需对数据进行相应处理即可。模型的一般形式仍然可以用模型 (2-3) 表示，只是相应的变量发生了些许的改变：

$$Y = X\beta + \varepsilon, \quad (2-4)$$

其中， $Y = (Y_1, \dots, Y_n)^T$ 是 $n \times 1$ 维响应向量， $X = (X_{ij})$ 是 $n \times p_n$ 维预测变量矩阵， $\beta = (\beta_1, \dots, \beta_{p_n})^T$ 是只有 s 个非零元素的 $p_n \times 1$ 维稀疏向量， $\varepsilon = (\varepsilon_1, \dots, \varepsilon_n)^T$ 是随机误差项，符号“ T ”表示矩阵的转置。

2.3 经典线性回归模型的基本假设

为了更好地进行模型的参数估计，经典线性回归模型通常有如下假设：

- (1) 随机误差项 ε_i 的期望为 0，即

$$E(\varepsilon_i) = 0, \quad i = 1, 2, \dots, n.$$

- (2) 随机误差项的方差均相同，不随预测变量的变动而呈现某种趋势，即

$$\text{var}(\varepsilon_i) = \tau^2, \quad i = 1, 2, \dots, n.$$

- (3) 随机误差项服从正态分布，即

$$\varepsilon_i \sim N(0, \tau^2), \quad i = 1, 2, \dots, n.$$

- (4) 随机误差项之间相互独立，即

$$\text{cov}(\varepsilon_i, \varepsilon_j) = 0, \quad i \neq j.$$

- (5) 预测变量不是随机变量，是确定性变量，且与随机误差项不相关，即

$$\text{cov}(X_{ik}, \varepsilon_i) = 0, \quad i = 1, 2, \dots, n, \quad k = 1, 2, \dots, j.$$

- (6) 预测变量之间不存在多重共线性。

在这些条件均满足的情况下，就可以使用线性回归模型进行有效建模，并得到准确的结果。

第3章 测量误差模型

目前,在大多数的研究中通常会默认模型所考虑的变量是精确的。然而,由于外界因素、观测者的技术水平和仪器本身校正不完善等原因,都可能导致测量误差的存在,即变量的观测值并不是真实值,而是存在偏差的值,如血压测量^[1]和CD4细胞计数^{[2][3]}。如果在估计模型的未知参数时忽略测量误差的存在,那么必然会导致所得到的参数估计是非一致的估计。因此,在进行模型分析时,考虑测量误差的存在并正确克服其带来的影响,可以使得模型的估计效果更佳,也能拓宽模型的使用范围。

3.1 Classical 测量误差

根据观测变量与真实值之间的关系,Fuller一书^[8]中将测量误差分为三类:Classical 测量误差(又称经典测量误差)、Berkson 测量误差以及 Classical 和 Berkson 混合测量误差。其中,应用最广泛和最常见的是 Classical 测量误差。本文仅考虑了 Classical 可加测量误差。

对于线性回归模型(2-3),当预测变量 X 存在测量误差时, X 不再是确定性变量,而是随机变量。记变量 X 的观测值为 W ,测量误差为 A ,则 Classical 可加测量误差模型的形式如下:

$$W = X + A, \quad (3-1)$$

其中, $A = (a_{ij})_{n \times j}$ 与 (X, ε) 独立。

存在测量误差时,可以发现不满足经典线性回归模型基本假设的第(5)点。如果仍然使用线性回归模型对数据进行建模分析,则会使得模型效果不佳。但是,可以通过联立方程(2-3)和(3-1)建立线性测量误差模型进行建模分析,形式如下:

$$\begin{cases} Y = X\beta + \varepsilon, \\ W = X + A, \end{cases} \quad (3-2)$$

模型(3-2)中由于使用的是 Classical 测量误差,故可称为 Classical 线性测量误差模型。

3.1.1 Classical 测量误差对线性回归模型参数估计的影响

为了阐述测量误差对模型参数估计的影响，下面分别从实例和理论的角度进行说明。考虑 Classical 线性测量误差模型：

$$\begin{cases} Y = X\beta + \varepsilon, \\ W = X + A, \end{cases} \quad (3-3)$$

假设 $X \sim N(0, 1)$, $\varepsilon \sim N(0, 0.25)$, $A \sim N(0, 1)$, $\beta = 3$ 。图3-1中红点表示真实数据 (Y, X) ，红线为真实数据下拟合的直线；蓝点表示含有测量误差的观测数据 (Y, W) ，蓝线为观测数据下拟合的直线。由此可见，当测量误差存在时，若不加以处理，会对模型的参数估计造成巨大的影响。




图 3-1 Classical 测量误差的影响

另一方面，从理论的角度进行分析。当不存在测量误差时，对模型 $(Y = X\beta + \varepsilon)$ 进行参数估计的常用方法是最小二乘法，由此得到模型参数的估计量具有无偏、一致和有效性，参数估计的表达式如下：

$$\hat{\beta} = [X^T X]^{-1} X^T Y. \quad (3-4)$$

当测量误差存在且不进行相应处理时，同样使用最小二乘法对模型 $(Y = W\beta + \varepsilon)$ 进行参数估计，得到的参数估计表达式为：

$$\hat{\gamma} = [W^T W]^{-1} W^T Y. \quad (3-5)$$

根据模型的相关假设，进一步分析估计量 $\hat{\gamma}$ 的相关性质，可以得到 $\hat{\gamma}$ 的期望为：

$$E(\hat{\gamma}) = \Sigma_{WW}^{-1} \Sigma_{WY} = (\Sigma_{XX} + \Sigma_{AA})^{-1} \Sigma_{XX} \beta. \quad (3-6)$$

由于 $(\Sigma_{XX} + \Sigma_{AA})^{-1} \Sigma_{XX}$ 通常不等于 1，因此 $E(\hat{\gamma}) \neq \beta$ ，说明 $\hat{\gamma}$ 是 β 的有偏估计。此外，参数的估计值也会随着测量误差的增大而逐渐减小。这同样也说明了测量误差的存在会对模型的参数估计造成影响。

3.1.2 参数估计方法

当 Classical 测量误差存在时, 为克服其对模型参数估计的影响, 常用的参数估计方法有矩估计方法和工具变量法等。

简单起见, 考虑不带截距项的一元线性回归测量误差模型:

$$\begin{cases} Y = X\beta + \varepsilon, \\ W = X + A, \end{cases} \quad (3-7)$$

通常假设随机误差项 $\varepsilon \sim N(0, \tau^2)$, 测量误差 $A \sim N(0, \sigma_a^2)$, X 与 A , ε 两两不相关。

对于模型 (3-7), 如果用传统的矩估计方法, 在实际应用中则会存在着辨识问题, 即 σ_a^2 在实际中未知。因此, 为了解决此问题, 引入了工具变量进行参数估计, 该方法称为工具变量法。

假设 Z 为工具变量, 则 Z 与 X 满足如下线性关系:

$$X = \alpha_0 + \alpha_1 Z + \delta_0, \quad (3-8)$$

其中, Z 与测量误差 A 无关, 且 $\delta_0 \sim N(0, \sigma_{\delta_0}^2)$ 。

有了工具变量之后, 就可以对模型进行参数估计, 将式 (3-8) 带入式 (3-7) 得到:

$$\begin{cases} Y = \eta_0 + \eta_1 Z + \nu, \\ W = \alpha_0 + \alpha_1 Z + (\delta_0 + A), \end{cases} \quad (3-9)$$

其中

$$\begin{cases} \eta_0 = \alpha_0 \beta, \\ \eta_1 = \alpha_1 \beta, \\ \nu = \delta_0 \beta + \varepsilon. \end{cases} \quad (3-10)$$

由于 ν 与 Z 不相关, 对 (3-9) 第一个等式使用最小二乘法可得 η_0 和 η_1 的无偏估计:

$$\begin{cases} \hat{\eta}_1 = S_{ZZ}^{-1} S_{ZY}, \\ \hat{\eta}_0 = \bar{Y} - \hat{\eta}_1 \bar{Z}, \end{cases} \quad (3-11)$$

其中 S_{ZZ} 为 Z 的样本协方差矩阵, S_{ZY} 为 Z 和 Y 的样本协方差矩阵。

同理, 对 (3-9) 第二个等式使用最小二乘法可得 α_0 和 α_1 的无偏估计:

$$\begin{cases} \hat{\alpha}_1 = S_{ZZ}^{-1} S_{ZW}, \\ \hat{\alpha}_0 = \bar{W} - \hat{\alpha}_1 \bar{Z}, \end{cases} \quad (3-12)$$

从而, 反解 (3-10) 得到参数 β 的一致估计 $\hat{\beta} = S_{ZW}^{-1} S_{ZY}$ 。

3.2 扭曲测量误差

Classical 测量误差通常会假设其服从正态分布，该假设会限制模型的应用，而扭曲测量误差则不会对误差分布做出任何假设，与不同模型的结合，能够拓宽模型的应用。本文主要考虑可加扭曲测量误差，与线性模型结合的一般形式如下：

$$\begin{cases} Y = X\beta + \varepsilon, \\ \tilde{Y} = Y + \phi(U), \\ \tilde{X} = X + \psi(U), \end{cases} \quad (3-13)$$

其中， Y 为响应变量， X 为预测变量，均是真值且不可被观测的； $\tilde{Y}$ 和 $\tilde{X}$ 是观测值； $\phi(\cdot)$ 和 $\psi(\cdot)$ 是观测到的混杂变量 U 的扭曲函数。

3.2.1 扭曲测量误差的影响

为了阐述扭曲测量误差对模型参数估计的影响，下面以实例进行说明。在模型 (3-13) 中，假设 $X \sim N(0, 1)$ ， $U \sim N(1, 1)$ ， $\phi(U) = (U - 1)/2$ ， $\psi(U) = (U + 1)^2 - 5$ ， $\beta = 2$ 。图 (3-2) 中红点表示真实数据 (Y, X) ，红线为真实数据下拟合的直线；蓝点表示含有扭曲测量误差的观测数据 $(\tilde{Y}, \tilde{X})$ ，蓝线为观测数据下拟合的直线。由此可知，若不对扭曲测量误差进行相应处理，将会对模型的参数估计造成十分巨大的影响，严重影响模型的估计效果。




图 3-2 扭曲测量误差的影响

3.2.2 参数估计方法

模型 (3-13) 不同于经典线性模型，该模型中的响应变量和预测变量均是不可被观测的，只能得到扭曲之后的观测值。因此，通常使用核密度估计法对扭曲函数的分布进行估计，从而恢复不能被直接观测的响应变量和预测变量的值。随后，基于此数据，就可以采用最小二乘法等常用的参数估计方法对模型的参数进行估计。

核密度估计是一种从数据样本本身出发研究数据分布特征的非参数检验方法,最初由 Rosenblatt^[37] 和 Parzen^[38] 提出。假设 $U_1, U_2, \dots, U_n$ 为独立同分布 F 的 n 个样本点,其概率密度函数为 $f(U)$,则利用核密度估计法可得到 $f(U)$ 的密度函数估计 $\hat{f}(U)$,计算公式如下:

$$\hat{f}(U) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{U - U_i}{h}\right), \quad (3-14)$$

其中, $K(\cdot)$ 为核密度函数, h 为窗宽。

第4章 带 Classical 可加测量误差的高维线性模型的变量选择和参数估计

本章主要研究高维线性模型中变量存在 Classical 可加测量误差时的变量选择和参数估计。首先,在高维线性模型下考虑 Classical 可加测量误差,并建立了相关模型。其次,结合无偏估计量,采用 Lasso 惩罚最小二乘法构建了求解模型参数的目标函数,由于目标函数通常是非凸函数,因此提出了基于 F 范数寻找最近正定矩阵的方法,即将非凸目标函数转换为凸函数;此外,还将 SCAD 惩罚函数与此方法进行了结合。接下来,使用坐标下降法对目标函数进行求解,并推导了相应参数估计的理论性质。最后,对上述方法进行了 Monte Carlo 数值模拟,结果表明所提出的方法能够较好地解决上述问题,且与 SCAD 惩罚函数结合的方法有着更优的性能,并将此方法应用在了 Boston housing 数据集和利尿剂抵抗数据集中。

4.1 符号与模型

高维线性模型表示如下:

$$Y = X\beta^* + \varepsilon, \quad (4-1)$$

其中, $Y = (Y_1, Y_2, \dots, Y_n)^T$ 是 $n \times 1$ 维响应变量, $X = (X_{ij})$ 是 $n \times p_n$ 维预测变量矩阵, β^* 是一个只有 s 个非零元素的 $p_n \times 1$ 维稀疏向量, $\varepsilon = (\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n)^T$ 是 $n \times 1$ 维随机误差项。

Classical 可加测量误差模型可以表示成:

$$W_{ij} = X_{ij} + a_{ij}, \quad (4-2)$$

其中, W_{ij} 是真实值 X_{ij} 的观测值, a_{ij} 表示测量误差, 假设 $a_{ij} \sim N(0, \sigma^2)$, 同时与 X_{ij} 、 ε_i 独立。在实际中, 通常使用重复数据来得到测量误差方差的估计值。

基于此模型, 下面给出一些必要的符号和假设。对于任意矩阵 $K = (k_{ij})$, $K > 0$ (≥ 0) 表示矩阵 K 是正定的 (半正定的)。 $\Lambda_{\min}(K)$ 和 $\Lambda_{\max}(K)$ 分别表示矩阵 K 的最小和最大特征值。假设所有的变量都是中心化的, 因此截距项不包含在模型中, 且协方差矩阵的每一列均被归一化, 即 $\frac{1}{n} \sum_{i=1}^n X_{ij}^2 = 1, (j = 1, \dots, p_n)$ 。不失一般性, 假设 $S = 1, 2, \dots, s$ 是回归系数向量的真正支集且记 $\beta^* = (\beta_S^{*T}, 0^T)^T$, 相

应的矩阵 X 可以写成 $X = (X_S, X_{S^c})$, Σ 也可以写成如下形式:

$$\Sigma = \begin{bmatrix} \frac{1}{n} X_S^T X_S & \frac{1}{n} X_S^T X_{S^c} \\ \frac{1}{n} X_{S^c}^T X_S & \frac{1}{n} X_{S^c}^T X_{S^c} \end{bmatrix} = \begin{bmatrix} \Sigma_{S,S} & \Sigma_{S,S^c} \\ \Sigma_{S^c,S} & \Sigma_{S^c,S^c} \end{bmatrix}.$$

因此, 真正的模型可以写成 $Y = X_S \beta_S^* + \varepsilon$, 其中 β_S^* 的元素均不为零。在以往的研究中, 通常假设 ε_i 是独立同分布的, 参数为 τ^2 的亚高斯随机变量, 我们同样使用此假设。

4.2 参数估计

在本节中, 基于随机样本 $(Y_i, W_{i1}, W_{i2}, \dots, W_{ip_n})$, $i = 1, \dots, n$, 采用 Lasso 惩罚最小二乘法, 并结合无偏估计量构建求解模型参数的目标函数, 由于目标函数通常是非凸函数, 因此提出了基于 F 范数寻找最近正定矩阵的方法, 即将非凸目标函数转换为凸函数。此外, 还将 SCAD 惩罚函数与此方法进行了结合。借助坐标下降法得到了 (4-1) 和 (4-2) 中未知参数的估计, 并达到了变量选择的效果。

4.2.1 Lasso 惩罚最小二乘法

最小绝对收缩和选择算子 (Least absolute shrinkage and selector operation, Lasso) 方法最初是由 Robert Tibshirani^[22] 提出, 是一种使用 l_1 范数的压缩估计方法。其基本思想是在模型回归系数的绝对值之和小于一个常数的约束条件下, 使得残差平方和达到最小, 从而可以产生某些严格等于 0 的模型回归系数, 得到可解释的回归模型。当协变量不存在测量误差时, 使用 Lasso 惩罚最小二乘法构建求解模型的未知参数是通过最小化如下目标函数:

$$\hat{\beta} = \arg \min_{\beta} \frac{1}{2n} \|Y - X\beta\|^2 + \lambda \|\beta\|_1, \quad (4-3)$$

其中, $\lambda > 0$ 为正则化参数。

简单起见, 考虑 Lasso 惩罚最小二乘问题的单变量形式, 等价于如下形式:

$$\frac{1}{2} (z_j - \beta_j)^2 + \lambda |\beta_j|, \quad (4-4)$$

从而可求得 Lasso 估计量的闭式解为:

$$\hat{\beta}_j = \text{sgn}(z_j)(|z_j| - \lambda)_+, \quad (4-5)$$

其中, z_j 是 $X^T Y$ 的第 j 个分量, a_+ 表示 a 的正部。

从上述闭式解可以看出, 如果普通最小二乘估计量的值小于 λ , 则 Lasso 估计量会将其缩小到 0。此外, Lasso 的复杂程度由正则化参数 λ 控制, λ 越大表示模型的惩罚力度就越大, 进而就可以得到一个变量较少的模型。因此, λ 的选择尤其重要, 常用交叉验证的方法选择最优 λ 。

Lasso 是最广泛和最流行的惩罚术语, 由于它对预测及变量选择的统计精度和计算的可行性而使得其在高维估计问题中得到广泛运用。然而, Lasso 仍然存在一些缺点。一是 Lasso 不能选择比样本数量更多的特征, 即在高维数据中, Lasso 最多只能选择 n 个预测变量; 二是由于 Lasso 的正则化参数 λ 不变, 惩罚力度为一常数, 对所有回归系数的惩罚力度均相同, 这可能导致出现过度压缩非零系数的情况, 使得估计结果的偏差增大。从统计理论的角度来看, Lasso 不具有 Oracle 性质 (在一些未知参数的情况下, 以概率 1 选择出正确的模型, 即模型选择的相合性; 非零系数的估计量具有相同的均值和协方差的渐近正态性); 三是 Lasso 只能选择单个的变量, 不适用于具有组结构的变量选择问题。

去除无关项, 目标函数 (4-3) 可转化为:

$$\hat{\beta} = \arg \min_{\beta} \frac{1}{2} \beta^T \Sigma \beta - \rho^T \beta + \lambda \|\beta\|_1, \quad (4-6)$$

其中, $\Sigma = \frac{1}{n} X^T X$, $\rho = \frac{1}{n} X^T Y$ 。

当预测变量存在 Classical 可加测量误差时, 有

$$E[\frac{1}{n} W^T W] = \frac{1}{n} X^T X + \sigma^2 I, \quad E[\frac{1}{n} W^T Y - \frac{1}{n} X^T Y] = 0. \quad (4-7)$$

因此, 采用 Loh 和 Wainwright^[33] 建议的无偏估计量, 从而得到求解模型未知参数是通过最小化如下目标函数:

$$\frac{1}{2} \beta^T \hat{\Sigma} \beta - \tilde{\rho}^T \beta + \lambda \|\beta\|_1, \quad (4-8)$$

其中, $\hat{\Sigma} = \frac{1}{n} W^T W - \sigma^2 I$ 和 $\tilde{\rho} = \frac{1}{n} W^T Y$ 分别是 Σ 和 ρ 的无偏估计量, I 为 $p_n \times p_n$ 维单位矩阵。

然而, 由于测量误差的存在, 很容易发现 $\hat{\Sigma}$ 在高维情形下通常不是正定矩阵, 这导致目标函数 (4-8) 不是凸函数, 从而没有全局最优解。针对此问题, Datta 和 Zou^[34] 定义了一个最近半正定矩阵投影算子, 从而提出了 CoCoLasso 估计器。投影算子的计算公式如下, 对任意方阵 K ,

$$(K)_+ = \arg \min_{K_1 \geq 0} \|K - K_1\|_{\max}, \quad (4-9)$$

其中, $\|K\|_{\max} = \max_{i,j} |K_{ij}|$ 。

在 CoCoLasso 估计器中, $\max$ 范数起着非常重要的作用, 它确保了 $(\hat{\Sigma})_+$ 近似于 Σ 。此外, $\max$ 范数与其它范数相比时, 如 l_1 范数和 F 范数, $\max$ 范数会使得近似估计的偏差更小。但是在求解过程中, $(\hat{\Sigma})_+$ 的计算是非常耗时的, 计算成本是非常昂贵的, 这是因为模型 (4-9) 是包含 p_n^2 个变量的凸程序, 且含有非光滑项。

因此, 为降低计算成本, 减少计算时长, 采用 F 范数来寻找最近正定矩阵,

计算形式如下：对于任意方阵 K ，

$$(K)_+ = \arg \min_{K_1 > 0} \|K - K_1\|_F. \quad (4-10)$$

随后，令 $\tilde{\Sigma} = (\hat{\Sigma})_+$ ，从而建立求解模型未知参数的最终表达式：

$$\hat{\beta} = \arg \min_{\beta} \frac{1}{2} \beta^T \tilde{\Sigma} \beta - \tilde{\rho}^T \beta + \lambda \|\beta\|_1. \quad (4-11)$$

根据定义， $\tilde{\Sigma}$ 总是正定的，从而也可以将问题重新表示成 Lasso 惩罚最小二乘形式：

$$\hat{\beta} = \arg \min_{\beta} \frac{1}{2n} \|\tilde{Y} - \tilde{W}\beta\|^2 + \lambda \|\beta\|_1, \quad (4-12)$$

其中， $\frac{1}{n} \tilde{W}^T \tilde{W} = \tilde{\Sigma}$ ， $\tilde{W}^T \tilde{Y} = \tilde{\rho}$ 。

对于目标函数 (4-11) 的求解，可以采用求解 Lasso 估计器的方法，如坐标下降法或最小角回归算法。在本章中，主要使用坐标下降法进行求解。

坐标下降法是一个简单但却高效的非梯度优化算法，它的核心思想是将一个复杂的优化问题分解成一系列简单的优化问题进行求解。我们知道，在高维情形下，最小化目标函数 (4-11) 时并不是一件容易的事情，而坐标下降法就是迭代地通过将大多数自变量 $\beta_1, \beta_2, \dots, \beta_{j-1}, \beta_{j+1}, \dots, \beta_{p_n}$ 视为已知常量，而只针对剩余的自变量 β_j 求极值的过程。这样就将一个高维的优化问题分解成了多个一维的优化问题，大大降低了问题的复杂度。那么，对于任何给定的初始值 $\beta^{(k)}$ ，目标函数 (4-11) 关于 β_j 的闭式解为：

$$\hat{\beta}_j^{(k+1)} = S(z_j, \lambda) / \tilde{\Sigma}_{jj}, \quad (4-13)$$

其中， $z_j = \tilde{\rho}_j - \tilde{\Sigma}_j^T \beta^{(k)} + \tilde{\Sigma}_{jj} \beta_j^{(k)}$ ， $\tilde{\Sigma}_j$ 表示 $\tilde{\Sigma}$ 的第 j 列， S 是由 Donoho 和 Johnstone^[39] 定义的软阈值算子，即对任意的 $\lambda \geq 0$ ，有

$$S(z, \lambda) = \begin{cases} z - \lambda, & \text{if } z > \lambda. \\ 0, & \text{if } |z| \leq \lambda. \\ z + \lambda, & \text{if } z < -\lambda. \end{cases}$$

因此，求解目标函数 (4-11) 的坐标下降法可以描述为如下三个步骤：

Step 1 选取初始值 $\beta^{(0)}$ ；

Step 2 令 $\beta^{(k)} = \beta^{(0)}$ ，则根据上面的迭代公式 (4-13) 可计算得出 $\beta_j^{(k+1)}$ ；

Step 3 不断地重复进行 Step 2 直到最后的系数估计量收敛。

为了实现上述的算法，需要事先选择出惩罚函数中的正则化参数 λ ，这将在 4.2.3 小节中详细说明。

4.2.2 SCAD 惩罚最小二乘法

Fand 和 Li^[24] 指出一个好的惩罚函数应该得到一个具有如下三个性质的估计量：

- (1) 无偏性：当真实的未知参数较大时，估计量几乎是无偏的，以避免不必要的建模偏差；
- (2) 稀疏性：所得到的估计量是一个阈值规则，它会自动将小的估计系数设为零，以降低模型的复杂度；
- (3) 连续性：所得到的估计量在数据 $z = X^T Y$ (普通最小二乘估计) 中是连续的，以避免模型预测的不稳定。

由于 Lasso 惩罚估计量不能同时满足无偏性、稀疏性和连续性，为了克服 Lasso 在理论上的不足，Fand 和 Li 提出了平滑剪切绝对偏差 (Smoothly clipped absolute deviation, SCAD) 惩罚函数^[24]。简单起见，考虑 SCAD 惩罚函数的单变量形式及其一阶导形式：

$$p_\lambda(\beta_j) = \begin{cases} \lambda|\beta_j|, & \text{if } |\beta_j| \leq \lambda. \\ \{-|\beta_j|^2 + 2\gamma\lambda|\beta_j| - \lambda^2\}/\{2(\gamma - 1)\}, & \text{if } \lambda < |\beta_j| \leq \gamma\lambda. \\ \frac{\lambda^2(\gamma+1)}{2}, & \text{if } |\beta_j| > \gamma\lambda. \end{cases} \quad (4-14)$$

$$p'_\lambda(|\beta_j|) = \lambda\{I(|\beta_j| \leq \lambda) + \frac{(\gamma\lambda - |\beta_j|)_+}{(\gamma - 1)\lambda}I(|\beta_j| > \lambda)\}, \quad (4-15)$$

其中， $\lambda > 0$ ， $\gamma > 2$ 。

在单变量情形下，SCAD 估计量的闭式解为：

$$\hat{\beta}_j = \begin{cases} \text{sgn}(z_j)(|z_j| - \lambda)_+, & \text{if } |z_j| \leq 2\lambda. \\ \{(\gamma - 1)z_j - \text{sgn}(z_j)\gamma\lambda\}/(\gamma - 2), & \text{if } 2\lambda < |z_j| \leq \gamma\lambda. \\ z_j, & \text{if } |z_j| > \gamma\lambda. \end{cases} \quad (4-16)$$

与单变量 Lasso 的闭式解 (4-5) 相比，可以看出，对较小的 β_j ，SCAD 如 Lasso 一样保持一致的惩罚力度 λ ，采取无差别惩罚，达到变量选择的效果。此外，除却一个短区间，SCAD 对大参数的估计是一致的。因此，SCAD 不仅能一致地选择重要变量，而且能产生与真实模型一样的有效参数估计量，即 SCAD 具有 Oracle 性质。

与 CoCoLasso 相比，4.2.1 小节中提出的方法由于使用了 F 范数，使得 $(\hat{\Sigma})_+$ 偏差较大，进而使得方法的性能也会较差一些。因此，为弥补方法性能的不足，采用性能更优的 SCAD 惩罚函数，并构建了求解模型未知参数的表达式：

$$\hat{\beta} = \arg \min_{\beta} Q_n(\beta) = \arg \min_{\beta} \frac{1}{2}\beta^T \tilde{\Sigma} \beta - \tilde{\rho}^T \beta + \sum_{j=1}^{p_n} p_\lambda(|\beta_j|), \quad (4-17)$$

其中， $\tilde{\Sigma}$ 和 $\tilde{\rho}$ 的定义与 4.2.1 小节中的定义一致， $p_\lambda(\cdot)$ 为 SCAD 惩罚函数。

在 Breheny 和 Huang^[40] 一文中指出坐标下降法同样适用非凸惩罚函数的变量选择方法，并且具有较好的性能。虽然 SCAD 惩罚函数是非凸惩罚，但是在 $\gamma > 2$ 时，SCAD 惩罚线性回归的目标函数就是凸函数。因此，只要选择合适的 γ ，目标函数 (4-17) 也将是凸函数。

对于目标函数 (4-17) 的求解, 同样采用坐标下降法。对于任何给定的初始值 $\beta^{(k)}$, 目标函数 (4-17) 关于 β_j 的闭式解为:

$$\hat{\beta}_j^{(k+1)} = \begin{cases} \frac{S(z_j, \lambda)}{\tilde{\Sigma}_{jj}}, & \text{if } |z_j| \leq \lambda \tilde{\Sigma}_{jj}. \\ \frac{S(z_j, \lambda \gamma / (\gamma - 1))}{\tilde{\Sigma}_{jj} - 1 / (\gamma - 1)}, & \text{if } \lambda (\tilde{\Sigma}_{jj} + 1) |z_j| \leq \gamma \lambda \tilde{\Sigma}_{jj}. \\ \frac{z_j}{\tilde{\Sigma}_{jj}}, & \text{if } |z_j| > \gamma \lambda \tilde{\Sigma}_{jj}. \end{cases} \quad (4-18)$$

其中, z_j 和 S 的定义与 4.2.1 小节中的一致, 则使用坐标下降法求解模型未知参数的步骤可概括为如下三步:

Step 1 选取初始值 $\beta^{(0)}$;

Step 2 令 $\beta^{(k)} = \beta^{(0)}$, 则根据上面的迭代公式 (4-18) 可计算得出 $\beta_j^{(k+1)}$;

Step 3 不断地重复进行 Step 2 直到最后的系数估计量收敛。

上述算法的实现需要事先选择出正则化参数 λ , 以及惩罚函数中的未知参数 γ 。对于 λ 的选择同样在 4.2.3 小节中详细说明, 而选择 $\gamma = 3.7$, 这是由文献 Fan 和 Li^[24] 得到的。

4.2.3 调优参数的选择

在 4.2.1 和 4.2.2 小节中, 我们知道调优参数与惩罚估计之间有着密切的联系, 选择合适的调优参数才能使得变量选择的效果更佳。同时, 迭代算法的实现需要事先给定调优参数。因此, 调优参数的选择对模型方法的实现和性能至关重要。

在实际应用中, 交叉验证是惩罚方法广泛使用的调优参数选择方法。然而, 对于被测量误差破坏的数据, 直接使用交叉验证, 会使得结果产生偏差。下面以 K 折交叉验证进行说明, 当测量误差不存在时, 令 $(Y_k, X_k) (k = 1, 2, \dots, K)$ 为第 k 个子集的响应变量和预测变量的观测数据, $(Y_{(-k)}, X_{(-k)})$ 表示去除第 k 个子集后的数据, 则最优的 λ 是通过最小化如下目标函数:

$$\frac{1}{K} \sum_{k=1}^K \frac{1}{n_k} \|Y_k - X_k \hat{\beta}_k(\lambda)\|^2, \quad (4-19)$$

然而, 当测量误差存在时, 由于 X 是未知的, 式 (4-19) 不是直接可用的。如果简单地使用观测数据 (Y, W) , 那么最优的 λ 是通过最小化如下目标函数:

$$\frac{1}{K} \sum_{k=1}^K \frac{1}{n_k} \|Y_k - W_k \hat{\beta}_k(\lambda)\|^2, \quad (4-20)$$

其中, $\hat{\beta}_k(\lambda)$ 是在数据为 $(Y_{(-k)}, W_{(-k)})$, 调优参数为 λ 时的系数估计值。从式 (4-20) 中可以发现, 即使采用本章方法计算出的 $\hat{\beta}_k(\lambda)$ 克服了测量误差的影响, 但由于式中仍然使用了被测量误差破坏的数据 $W_{(-k)}$, 因此会导致交叉验证的结果产生偏差。

对式 (4-19) 使用简单的代数运算, 可得:

$$\tilde{\lambda} = \arg \min_{\lambda} \sum_{k=1}^K \hat{\beta}_k(\lambda)^T \Sigma_k \hat{\beta}_k(\lambda) - 2\rho_k^T \hat{\beta}_k(\lambda). \quad (4-21)$$

其中, $\Sigma_k = \frac{1}{n_k} X_k^T X_k$, $\rho_k = \frac{1}{n_k} X_k^T Y_k$ 。

在式 (4-21) 中使用无偏估计量 $\hat{\Sigma}_k$ 和 $\tilde{\rho}_k$ 可以克服偏差问题, 但是由于 $\hat{\Sigma}_k$ 可能具有负特征值, 这将导致调优参数 λ 的求解存在问题。

因此, 采用第4.2.1小节中方法构建的思想, 即在式 (4-21) 中使用 $(\hat{\Sigma}_k)_+$ 和 $\tilde{\rho}_k$ 。通过此修正, 交叉验证选择的 λ 被定义为:

$$\hat{\lambda} = \arg \min_{\lambda} \sum_{k=1}^K \hat{\beta}_k(\lambda)^T (\hat{\Sigma}_k)_+ \hat{\beta}_k(\lambda) - 2\tilde{\rho}_k^T \hat{\beta}_k(\lambda). \quad (4-22)$$

其中, $\hat{\Sigma}_k = \frac{1}{n_k} W_k^T W_k - \sigma^2 I$, $\tilde{\rho}_k = \frac{1}{n_k} W_k^T Y_k$, I 为 $n_k \times n_k$ 维单位矩阵。

4.3 理论性质

本节在参考 Datta 和 Zou^[34], Li 等人^[36], Bickel^[41], Wainwright 等人^[42], Zou^[43] 以及 Xu^[44] 等文献之后, 结合本章所提出的方法, 分别对 Lasso 惩罚估计量和 SCAD 惩罚估计量的理论性质进行讨论。在给出相关性质之前, 先给出如下条件:

(A1) $\hat{\Sigma}$ 和 $\tilde{\rho}$ 的分布可以被参数 θ 识别, 则存在常数 C 和 c , 以及依赖于 θ 和 σ^2 的正函数 ζ 和 ε_0 , 使得对任意的 $\varepsilon \leq \varepsilon_0$, $\hat{\Sigma}$ 和 $\tilde{\rho}$ 满足以下概率不等式:

$$\Pr(|\hat{\Sigma}_{ij} - \Sigma_{ij}| \geq \varepsilon) \leq C \exp(-c n \varepsilon^2 \zeta^{-1}) \quad \forall i, j = 1, \dots, p, \quad (4-23)$$

$$\Pr(|\tilde{\rho}_j - \rho_j| \geq \varepsilon) \leq C \exp(-c n s^{-2} \varepsilon^2 \zeta^{-1}) \quad \forall j = 1, \dots, p.$$

(A2) Compatibility condition:

$$0 < \Omega = \min_{x \neq 0, \|x_{S^c}\|_1 \leq 3\|x_S\|_1} \frac{x^T \hat{\Sigma} x}{\|x\|^2}. \quad (4-24)$$

(A3) 不可表示和最小特征值条件:

$$\|\hat{\Sigma}_{S^c, S} \hat{\Sigma}_{S, S}^{-1}\|_{\infty} = 1 - \gamma_1 < 1, \quad \Lambda_{\min}(\hat{\Sigma}_{S, S}) = C_{\min} > 0. \quad (4-25)$$

(A4) 存在常数 C_1 和 C_2 , 使得

$$0 < C_1 < \Lambda_{\min}(\Sigma) < \Lambda_{\max}(\Sigma) < C_2. \quad (4-26)$$

(A1) 是要求无偏估计量 $\hat{\Sigma}$ 和 $\tilde{\rho}$ 在 F 范数下分别近似于 Σ 和 ρ , 在引理 1 中给出满足此假设的证明; (A2) 是便于推导 Lasso 估计量的统计误差边界; (A3) 是便于推导 Lasso 估计量的符号一致性; (A4) 是线性模型文献中的一个经典条件。

同样需要对 SCAD 惩罚函数做出以下假设。令 $a_n = \max\{|p'_{\lambda}(\beta_j^*)| : \beta_j^* \neq 0\}$, $b_n = \max\{|p''_{\lambda}(\beta_j^*)| : \beta_j^* \neq 0\}$, 其中 β_j^* 是 β^* 的第 j 个分量。

(A5) $\liminf_{n \rightarrow \infty} \liminf_{\theta \rightarrow 0_+} p'_{\lambda}(\theta)/\lambda > 0$.

(A6) $a_n = O(n^{-1/2})$.

(A7) 当 $n \rightarrow \infty$ 时, $b_n \rightarrow 0$.

(A8) 存在常数 C 和 D , 使得当 $\theta_1, \theta_2 > C\lambda$ 时, 有 $|p''_\lambda(\theta_1) - p''_\lambda(\theta_2)| \leq D|\theta_1 - \theta_2|$.

引理 4.1 令 $\zeta = \max(\tau^4, \sigma^4, 1)$ 和 $\varepsilon_0 = \tau^2$, 则式 (4-8) 中的 $\hat{\Sigma}$ 和 $\tilde{\rho}$ 满足假设条件 (A1)。

下面给出有关 Lasso 惩罚估计量的相关理论性质。

定理 4.1 假设条件 (A1)-(A2) 都满足且 $\lambda \leq \min(\varepsilon_0, 12\varepsilon_0\|\beta_S^*\|_\infty)$, 则以下结论至少以概率 $1 - \delta_1$ 成立, 其中 $\delta_1 = p_n^2 C \exp(-ncp_n^{-2}s^{-2}\varepsilon^2\zeta^{-1}) + p_n^2 C \exp(-ncs^{-2}\lambda^2\zeta^{-1})$:

$$(l_1 \text{ 和 } l_2 \text{ 误差}) \quad \|\hat{\beta} - \beta^*\| \leq C\lambda\sqrt{s}/\Omega, \quad \|\hat{\beta} - \beta^*\|_1 \leq C\lambda s/\Omega. \quad (4-27)$$

$$(\text{预测误差}) \quad \|X(\beta^* - \hat{\beta})\|/\sqrt{n} \leq C\lambda\sqrt{s}/\sqrt{\Omega}. \quad (4-28)$$

定理 4.2 假设条件 (A1) 和 (A3) 都满足且 $\lambda \leq \min(\varepsilon_0, 4\varepsilon_0/\gamma_1)$, $\varepsilon \leq \varepsilon_0^*$, ε_0^* 的详细定义可以参见定理的证明, 则以下结果至少以概率 $1 - \delta_2$ 成立, 其中 $\delta_2 = p_n^2 C \exp(-cns^{-2}\gamma_1^2\lambda^2\zeta^{-1}) + p_n^2 C \exp(-cnp_n^{-2}s^{-2}\varepsilon^2\zeta^{-1})$:

- (a) 存在唯一的一个解 $\hat{\beta}$ 最小化 (4-11);
- (b) $\|\hat{\beta}_S - \beta_S^*\|_\infty \leq \kappa\lambda$, 其中 $\kappa = (4\|\Sigma_{S,S}^{-1}\|_\infty + C_{\min}^{-1/2})$;
- (c) 如果 $|\beta_{\min}^*| \geq \kappa\lambda$, 则有 $\text{sign}(\hat{\beta}_S) = \text{sign}(\beta_S^*)$ 。

接下来给出有关 SCAD 惩罚估计量的渐近性质。

定理 4.3 假设条件 (A1) 和 (A4) 成立, 且惩罚函数 $p_\lambda(\cdot)$ 满足条件 (A5)-(A8)。如果 $n \rightarrow \infty$ 时, $p_n^2/n \rightarrow 0$, 那么如下式子成立的概率趋于 1,

$$\|\hat{\beta} - \beta^*\| = O_p\{\sqrt{p_n}(n^{-1/2} + a_n)\}.$$

为了得到 $\hat{\beta}$ 的渐近正态分布, 首先给出如下记号:

$$\Sigma_\lambda(\beta_S^*) = \text{diag}\{p''_\lambda(|\beta_1^*|), p''_\lambda(|\beta_2^*|), \dots, p''_\lambda(|\beta_s^*|)\},$$

$$B_n = \{p'_\lambda(|\beta_1^*|)\text{sgn}(\beta_1^*), p'_\lambda(|\beta_2^*|)\text{sgn}(\beta_2^*), \dots, p'_\lambda(|\beta_s^*|)\text{sgn}(\beta_s^*)\}^T.$$

定理 4.4 (Oracle 性质) 假设条件 (A1) 和 (A4) 成立, 且惩罚函数 $p_\lambda(\cdot)$ 满足条件 (A5)-(A8)。如果 $n \rightarrow \infty$ 时, $\lambda \rightarrow 0$, $\sqrt{n/p_n}\lambda \rightarrow \infty$ 且 $p_n^2/n \rightarrow 0$, 那么如下结论成立的概率趋于 1, 关于 (4-17) 的 $\sqrt{n/p_n}$ 一致的 SCAD 惩罚最小二乘估计量 $\hat{\beta} = (\hat{\beta}_S^T, \hat{\beta}_{S^c}^T)^T$ 满足:

(a)(稀疏性) $\hat{\beta}_{S^c} = 0$;

(b)(渐近正态性)

$$\sqrt{n}(\Sigma_{S,S}^{-1} + \Sigma_\lambda(\beta_S^*))[\hat{\beta}_S - \beta_S^* + (\Sigma_{S,S}^{-1} + \Sigma_\lambda(\beta_S^*))^{-1}B_n] \rightarrow N(0, \Sigma_{S,S}^2),$$

其中, $\Sigma^1 = \text{Cov}(w_1)$, $\Sigma^2 = \text{Cov}(v)$ 。

如果定理4.4成立, 我们知道 $\hat{\beta}_S$ 的渐近矩阵为

$$\Sigma_{asy} = (\Sigma_{S,S}^1 + \Sigma_\lambda(\beta_S^*))^{-1} \Sigma_{S,S}^2 (\Sigma_{S,S}^1 + \Sigma_\lambda(\beta_S^*))^{-1},$$

令

$$\hat{\Sigma}_\lambda(\hat{\beta}_S) = \text{diag}\{p''_\lambda(|\hat{\beta}_1|), p''_\lambda(|\hat{\beta}_2|), \dots, p''_\lambda(|\hat{\beta}_s|)\}, \quad \hat{\Sigma}^2 = \frac{1}{n} \sum_{i=1}^n \{W_i^T(Y_i - W_i \hat{\beta}) + \sigma^2 I \hat{\beta}\}^{\otimes 2},$$

其中, $K^{\otimes 2} = KK^T$, I 为 $p_n \times p_n$ 维单位矩阵。从而可得

$$(\hat{\Sigma}_{S,S} + \hat{\Sigma}_\lambda(\hat{\beta}_S))^{-1} \hat{\Sigma}_{S,S}^2 (\hat{\Sigma}_{S,S} + \hat{\Sigma}_\lambda(\hat{\beta}_S))^{-1} \xrightarrow{P} \Sigma_{asy}.$$

4.4 Monte Carlo 数值模拟

在本节中, 通过 Monte Carlo 数值模拟来评估本章所提出的方法在有限样本下变量选择和参数估计的效果。简单起见, 分别将4.2.1和4.2.2小节中的方法记为 F-Lasso 和 F-SCAD。为了进行比较, 将提出的方法与其它几种普遍的方法进行对比, 包括 Oracle(即测量误差不存在, 观测值为真值), Naive(即测量误差存在且被忽略, 同时使用 SCAD 惩罚函数) 和 CoCoLasso 方法。对于每一种方法, 使用 $SE = \|\hat{\beta} - \beta\|$ 作为评估参数估计误差的指标; 使用 C(正确识别重要预测变量的数量, 即非零系数中被估计为非零系数的个数) 和 IC(识别不相关预测变量的数量, 即零系数中被估计为非零系数的个数) 作为评估变量选择效果的指标。

模拟的模型为:

$$\begin{cases} Y = X\beta + \varepsilon, \\ W = X + A, \end{cases} \quad (4-29)$$

其中, X 服从多元正态分布, $X_k \sim N(0, 1)$, $k = 1, 2, \dots, p_n$; $a_{ij} \sim N(0, \sigma^2)$; 随机误差项 $\varepsilon \sim N(0, 0.25)$; $\beta = (\beta_1, \beta_2, \dots, \beta_{p_n})^T$ 且满足 $\beta_1 = \beta_2 = \beta_3 = 1, \beta_l = 0 (l = 4, \dots, p_n)$ 。

为了进行更好的比较, 还考虑了不同的样本量 n 、不同的预测变量数量 p_n 以及不同程度的测量误差 ($\sigma^2 = 0.2$, $\sigma^2 = 0.5$), 并在每次模拟中, 进行了 100 次 Monte Carlo 模拟。对于表中出现的 C, IC 和 SE 三种指标, 都是基于 100 次 Monte Carlo 模拟的平均值。

表4-1是本章所提出的 F-SCAD 方法与 CoCoLasso 方法在模拟中的性能比较结果。表4-2是为直观地观察两种方法的具体参数估计值, 从模拟 $(n, p_n, \sigma^2) = (200, 500, 0.2)$ 中列出的一次参数估计结果, 此表中未给出值的均为零。

从表4-1中可以发现, 这两种方法均能正确识别重要变量, 但随着测量误差严重程度的降低, 无论是变量选择的效果, 还是参数估计误差, 本章所提出的 F-SCAD 方法均要优于 CoCoLasso。同时, 表4-2表明了 F-SCAD 方法得到的参数估计值更接近真实值, 且有着更小的偏差。此外, 以模拟 $(n, p_n) = (200, 500)$ 为例, 图4-1呈现了这两种方法的 100 次模拟结果, 由于指标 C 的所有模拟结果均

表 4-1 使用 F-SCAD 和 CoCoLasso 方法求解模型未知参数的模拟结果

(n, p_n, σ^2)	方法	C	IC	SE
(100,300,0.2)	F-SCAD	3.00	7.11	0.295
	CoCoLasso	3.00	8.54	0.485
(100,300,0.5)	F-SCAD	3.00	13.40	0.639
	CoCoLasso	3.00	14.60	0.668
(150,400,0.2)	F-SCAD	3.00	4.19	0.233
	CoCoLasso	3.00	5.22	0.423
(150,400,0.5)	F-SCAD	3.00	9.50	0.561
	CoCoLasso	3.00	10.30	0.571
(200,500,0.2)	F-SCAD	3.00	2.52	0.206
	CoCoLasso	3.00	3.11	0.490
(200,500,0.5)	F-SCAD	3.00	7.15	0.551
	CoCoLasso	3.00	7.95	0.751

表 4-2 使用 F-SCAD 和 CoCoLasso 方法的参数估计值

参数	方法	
	F-SCAD	CoCoLasso
β_1	0.9923	0.8088
β_2	0.9251	0.7475
β_3	0.9605	0.7659
β_{19}	-0.0097	
β_{225}		0.0035

为 3，故未在图中呈现。

除了将 F-SCAD 方法与已有的 CoCoLasso 方法进行比较之外，还进行了如下模拟。表4-3展示了 F-SCAD、F-Lasso、Oracle 和 Naive 这四种方法之间的性能比较结果，而表4-4是从模拟 $(n, p_n, \sigma^2) = (200, 500, 0.2)$ 中列出的一次参数估计值，旨在直观地观察各个方法计算出的具体参数估计值，此表中未给出值的均为零。


由于 Naive 所使用的是 SCAD 惩罚函数，因此将 F-SCAD 方法与其比较，通过表4-3和表4-4，可以发现随着测量误差严重程度的增加，Naive 方法的变量选择效果越来越糟糕，且参数估计误差越来越大，这无疑说明了测量误差会对模型的参数估计和变量选择带来巨大的影响，而相比之下，F-SCAD 方法则有着更小的参数估计误差和更优的变量选择效果，这说明正确处理测量误差不仅能在一定程度上减小参数估计值的偏差，使得参数估计值更接近真实值，也能达到更优的

表 4-3 带 Classical 可加测量误差的高维线性模型的模拟结果

(n, p_n, σ^2)	方法	C	IC	SE
(100,300,0.2)	Oracle	3.00	1.90	0.097
	Naive	3.00	9.16	0.355
	F-SCAD	3.00	7.11	0.295
	F-Lasso	3.00	8.81	0.597
(100,300,0.5)	Oracle	3.00	2.79	0.093
	Naive	3.00	17.20	0.752
	F-SCAD	3.00	13.40	0.639
	F-Lasso	3.00	14.80	0.857
(150,400,0.2)	Oracle	3.00	1.10	0.070
	Naive	3.00	4.74	0.313
	F-SCAD	3.00	4.19	0.233
	F-Lasso	3.00	5.45	0.537
(150,400,0.5)	Oracle	3.00	1.18	0.074
	Naive	3.00	15.70	0.681
	F-SCAD	3.00	9.50	0.561
	F-Lasso	3.00	10.70	0.780
(200,500,0.2)	Oracle	3.00	0.66	0.060
	Naive	3.00	3.12	0.297
	F-SCAD	3.00	2.52	0.206
	F-Lasso	3.00	3.17	0.501
(200,500,0.5)	Oracle	3.00	0.56	0.061
	Naive	3.00	13.60	0.664
	F-SCAD	3.00	7.15	0.551
	F-Lasso	3.00	8.07	0.768

表 4-4 带 Classical 可加测量误差的高维线性模型的参数估计值

参数	方法		
	Naive	F-SCAD	F-Lasso
β_1	0.9213	0.9923	0.8012
β_2	0.8681	0.9251	0.7369
β_3	0.8831	0.9605	0.7655
β_{19}	-0.0050	-0.0097	
β_{225}			0.0037

图 4-1 $(n, p_n) = (200, 500)$ 的 100 次模拟结果

变量选择效果。

此外，对比本章所提出的 F-SCAD 和 F-Lasso 这两种方法，可以发现无论是变量选择效果，还是参数估计误差，前者总是优于后者，这也得益于 SCAD 惩罚函数是一个性能更优的惩罚函数。

综合上述模拟研究，无论测量误差严重程度如何，本章所提出的方法能够进行变量选择，且有效的估计参数值避免较大的偏差。总之，在处理高维线性模型带 Classical 可加测量误差时的变量选择和参数估计问题，与 SCAD 惩罚函数结合的方法有着较好的性能，能够很好地解决此类问题。

4.5 实例应用

4.5.1 Boston housing 数据集

本小节将性能更优的方法应用在 Boston housing 数据集上, 研究目的在于根据一些变量来预测房价。数据集包含 506 个观察结果和 14 个自变量, 包括 MEDV(以 1000 美元计算的自有住房的中位数)、NOX(pphm 的氮氧化物水平)、RM(平均房价数目)、AGE(1940 年以前建造的建筑比例)、B(黑人人口的比例)、LSTAT(较低地位人口比例)、CRIM(犯罪率)、ZN(大地块区域比例)、INDUS(非零售商业区比例)、TAX(财产税率)、PTRATIO(师生比例)、CHAS(毗邻 Charles River)、DIS(到就业中心加权距离) 和 RAD(辐射状公路的可达性指数)。关于变量的详细信息可以在 Harrison 和 Rubinfeld^[45] 一文中的表四找到。

对数据集进行中心化和标准化后, 考虑除了 CHAS 和 RAD 以外的变量都可能存在测量误差, 为进行偏差修正, 需要利用重复数据对测量误差的协方差矩阵进行估计。然而, 此数据集不存在重复数据, 不满足计算条件。于是, 采用 Li 等人^[46] 使用的方法, 对本章提出方法的敏感性进行分析。对模型中除了 CHAS 和 RAD 之外的变量, 人为地加入测量误差, 即

$$W_{ij} = X_{ij} + a_{ij}, \quad (4-30)$$

其中, $a_{ij} \sim N(0, \sigma^2)$, σ^2 分别取 0.2 和 0.5。

采用4.2.2小节中的方法对数据进行建模分析, 调优参数 λ 由五折交叉验证选择。表4-5和4-6分别列出了测量误差方差取 0.2 和 0.5 时的相关结果。表中 Ture 表示基于原始观测数据集, 使用 SCAD 惩罚函数计算得出的结果; Naive 表示加入测量误差后不进行偏差修正, 使用 SCAD 惩罚函数计算得出的结果; F-SCAD 是本章提出的对测量误差进行偏差修正的方法。

从表4-5和4-6可以看出, 随着测量误差严重程度的增加, Naive 方法得到了参数估计值越来越偏离真实数据 (True) 的推断结果, 有着较大的偏差, 且变量选择的效果越来越糟糕。而进行了偏差修正的 F-SCAD 估计则更接近真实数据 (True) 的推断结果, 且变量选择的效果更优。

4.5.2 利尿剂抵抗数据集

由于第4.5.1小节中的预测变量个数小于样本数量, 为进一步验证本章提出的方法在高维数据中的性能, 因此将提出的方法应用在利尿剂抵抗数据集上。该数据集来自于 2021 年天津市应用基础研究项目《基于统计学习的心力衰竭患者容量评估及调控策略研究》, 包含了 108 个观测结果和 109 个预测变量, 预测变量包含与身体状况、血常规、尿常规相关的属性以及其它指标, 详细信息可以参考

表 4-5 $\sigma^2 = 0.2$ 时模型参数估计结果

变量	方法		
	True	Naive	F-SCAD
RM	0.3671	0.3302	0.3874
AGE	0	0	0
DIS	0	0	0
RAD	0	0	0
TAX	0	0	0
PTRATIO	-0.0989	-0.0983	-0.0778
B	0	0.0263	0.0136
CRIM	0	0	0
ZN	0	0	0
INDUS	0	0	0
CHAS	0.0039	0.0093	0.0046
NOX	0	0	0
LSTAT	-0.4751	-0.3898	-0.4407

表 4-6 $\sigma^2 = 0.5$ 时模型参数估计结果

变量	方法		
	True	Naive	F-SCAD
RM	0.3671	0.2561	0.3578
AGE	0	0	0
DIS	0	0	0
RAD	0	0	0
TAX	0	0	0
PTRATIO	-0.0989	-0.1122	-0.0775
B	0	0.0579	0.0436
CRIM	0	-0.0087	0
ZN	0	0	0
INDUS	0	-0.0352	0
CHAS	0.0039	0.0254	0.0066
NOX	0	0	0
LSTAT	-0.4751	-0.3019	-0.4634

表4-7, 可以用于分析尿量与各个预测变量之间的关系。

表 4-7 预测变量信息

分类	属性
身体状况	是否患糖尿病、有无房颤(房扑)等
血常规	血钾、血钠、血氯、血肌酐、 白细胞、红细胞、红细胞压积等
尿常规	尿蛋白、尿钾、尿钠等
其它指标	ALT、AST、ALBI、TSH、FT3、FT4 等

先对数据进行相关预处理, 包括删除缺失值的样本、去除重复特征以及数据的中心化和标准化。除了年龄、诊断心衰时长和分类变量外, 由于白细胞等余下变量的相关数值可能是由仪器测量得出的, 因此考虑这些变量可能存在测量误差。此数据集中不存在重复数据, 于是仍然采用4.5.1小节中使用的方法, 对方法的敏感性进行分析。对模型中除了年龄、诊断心衰时长和分类变量之外的变量, 人为地加入测量误差, 即

$$W_{ij} = X_{ij} + a_{ij}, \quad (4-31)$$

其中, $a_{ij} \sim N(0, \sigma^2)$, σ^2 分别取 0.2 和 0.5。

对该数据所使用的方法和调优参数方法, 以及表中出现的 Ture, Naive 和 F-SCAD 都与4.5.1小节中的描述一致。

表 4-8 $\sigma^2 = 0.2$ 时模型参数估计结果

变量	方法		
	True	Naive	F-SCAD
当日入量	0.6635	0.5591	0.7362
负平衡量	0.9195	0.7274	0.9074
尿尿酸	0	0.0123	0
尿钠	0	0.0320	0
AST	0	0.0106	0
体重	-0.3200	-0.3444	-0.4095
诊断心衰时长	0	0.0045	0.0234

从表4-8和4-9可以看出, 进行偏差修正的 F-SCAD 估计与 Naive 相比, 前者更接近真实数据 (True) 的推断结果, 且变量选择的效果更优。

表 4-9 $\sigma^2 = 0.5$ 时模型参数估计结果

变量	方法		
	True	Naive	F-SCAD
血肌酐	0	-0.0516	0
尿比重	0	-0.0542	-0.0003
Lac(入院)	0	-0.0145	0
当日入量	0.6635	0.3225	0.3641
负平衡量	0.9195	0.5389	0.6879
舒张压 (前一日)	0	-0.0252	0
尿蛋白	0	0.0020	0
尿钠	0	0.0193	0
单核细胞绝对值	0	0.0252	0
红细胞分布宽度	0	-0.0492	0
红细胞平均血红蛋白量	0	-0.0122	0
总胆汁酸	0	-0.0822	-0.0191
线粒体同工酶	0	0.0804	0.0075
胱抑素	0	-0.0367	0
HsCRP	0	-0.0255	0
TSH	0	-0.0353	0
体重	-0.3200	-0.1094	-0.0198
有核红细胞绝对值	0	0.0296	0

4.6 定理证明

4.6.1 相关引理

本节主要对文中提出的引理和定理进行详细的证明。为了表述方便，将 C 和 c 表示为通用常数，其值可能在不同的表达式中发生变化，并给出以下符号以及定理中使用到的相关引理。

$$D = \tilde{\Sigma} - \Sigma, \quad G = \Sigma_{S^c, S} \Sigma_{S, S}^{-1}, \quad \tilde{G} = \tilde{\Sigma}_{S^c, S} \tilde{\Sigma}_{S, S}^{-1}, \quad H = \tilde{G} - G,$$

$$F = \tilde{\Sigma}_{S, S}^{-1} - \Sigma_{S, S}^{-1}, \quad \phi = \|\Sigma_{S, S}^{-1}\|_{\infty}, \quad \psi = \|\Sigma_{S, S}\|_{\infty}, \quad B = \|\beta_S^*\|_{\infty},$$

$$\delta_1(\varepsilon, \zeta) = p_n^2 C \exp(-cns^{-2}\varepsilon^2\zeta^{-1}), \quad \delta_2(\varepsilon, \zeta) = p_n^2 C \exp(-cnp_n^{-2}s^{-2}\varepsilon^2\zeta^{-1}).$$

定义 4.1 (亚高斯随机向量) 如果存在 $\tau_1 > 0$ ，使得对所有的 $t > 0$ 且 $\|v\| = 1$ ，有 $\Pr(|v^T(w - E(w))| > t) \leq 2 \exp(-\frac{t^2}{2\tau_1^2})$ ，则称 w 为亚高斯随机向量。

引理 4.2 对任意的 $\varepsilon > 0$ ，有

$$\Pr(\|\tilde{\Sigma} - \Sigma\|_F \geq \varepsilon) \leq p_n^2 \max_{i,j} \Pr(|\hat{\Sigma}_{ij} - \Sigma_{ij}| \geq \frac{\varepsilon}{2p_n}). \quad (4-32)$$

引理 4.3 在 Bickel^[41] 等一文中定义的 Restricted eigenvalue condition 如下:

$$\min_{B \subseteq \{1, 2, \dots, p\}, |B| \leq s} \min_{x \neq 0, \|x_{B^c}\|_1 \leq 4\|x_B\|_1} \min \frac{x^T \Sigma x}{\|x_B\|^2} = \Omega' > 0. \quad (4-33)$$

由此条件可以推导假设 (A2)。

引理 4.4 对任意向量 x , 令 $\partial\|x\|_1$ 表示 $\|x\|_1$ 的次梯度。那么可以得到如下结果:

(a) 如果在 $\partial\|\hat{\beta}\|_1$ 中存在向量 $\tilde{u}$ 使得

$$\tilde{\Sigma}\hat{\beta} - \tilde{\rho} + \lambda\tilde{u} = 0, \quad (4-34)$$

则 $\hat{\beta}$ 是 $\tilde{f}(\beta) = (1/2)\beta^T \tilde{\Sigma}\beta - \tilde{\rho}^T \beta + \lambda\|\beta\|_1$ 的最优解。

(b) 如果 $|\tilde{u}_j| < 1, \forall j \in S^c$, 则对任何其它最优解 $\tilde{\beta}$ 都满足 $S(\tilde{\beta}) \subseteq S$ 。

(c) 如果假设 $\tilde{\Sigma}_{S(\hat{\beta}), S(\hat{\beta})}$ 是可逆的, 那么在 (b) 部分的条件下, $\tilde{f}(\beta)$ 有唯一的极小值。

引理 4.5 对所有的 $\varepsilon \leq \min(\varepsilon_0, C_{\min}/2)$, 有

$$\Pr(\tilde{\Sigma}_{S,S} > 0) \geq 1 - \delta_2(\varepsilon, \zeta). \quad (4-35)$$

引理 4.6 如果 $\hat{\Sigma}$ 和 $\tilde{\rho}$ 满足假设 (A1), 则存在正常数 C 和 c , 使得对任意 $\varepsilon \leq \min(\varepsilon_0, 1/\phi)$, 有

$$\begin{aligned} \Pr(\|F\|_\infty \geq \varepsilon\phi^2(1 - \phi\varepsilon)^{-1}) &\geq \delta_2(\varepsilon, \zeta), \\ \Pr(\|H\|_\infty \geq \varepsilon\phi(2 - \gamma)(1 - \phi\varepsilon)^{-1}) &\geq \delta_2(\varepsilon, \zeta). \end{aligned} \quad (4-36)$$

根据 $\|\hat{\Sigma} - \Sigma\|_\infty \leq \|\hat{\Sigma} - \Sigma\|_F \leq p_n \|\hat{\Sigma} - \Sigma\|_{\max}$ 以及 $\|D\| \leq \|D\|_F$, 引理4.2、4.3和4.5的证明思路可以参考文献 Datta 和 Zou^[34], 引理4.4的证明可以参考文献 WAIN-WRIGHT 等人^[42], 引理4.6的证明可以参考文献 Datta 和 Zou^[34], Zou^[43]。

4.6.2 相关证明

引理 4.1的证明: 可以参考 Datta 和 Zou^[34] 中引理 1 的证明。□

定理 4.1的证明: 根据 (4-11) 中关于 $\hat{\beta}$ 的定义, 有

$$\frac{1}{2}\hat{\beta}^T \tilde{\Sigma}\hat{\beta} - \tilde{\rho}^T \hat{\beta} + \lambda\|\hat{\beta}\|_1 \leq \frac{1}{2}\beta^{*T} \tilde{\Sigma}\beta^* - \tilde{\rho}^T \beta^* + \lambda\|\beta^*\|_1. \quad (4-37)$$

令 $\hat{v} = \hat{\beta} - \beta^*$, 并带入上式, 可得

$$\begin{aligned} \frac{1}{2}\hat{v}^T \tilde{\Sigma}\hat{v} + \lambda\|\hat{\beta}\|_1 &\leq \hat{v}^T (\tilde{\rho} - \tilde{\Sigma}\beta^*) + \lambda\|\beta^*\|_1 \\ &\leq \|\hat{v}\|_1 \|\tilde{\rho} - \tilde{\Sigma}\beta^*\|_\infty + \lambda\|\beta^*\|_1. \end{aligned} \quad (4-38)$$

为了得到上述式子左边的上界, 首先需要对 $\|\tilde{\rho} - \tilde{\Sigma}\beta^*\|_\infty$ 进行约束。利用三角不等式, 可得:

$$\|\tilde{\rho} - \tilde{\Sigma}\beta^*\|_\infty \leq \|\tilde{\rho} - \rho\|_\infty + \|\rho - \Sigma\beta^*\|_\infty + \|D\beta^*\|_\infty. \quad (4-39)$$

根据假设 (A1) 可得, 对于 $\lambda \leq 6\epsilon_0$, 有 $P(\|\tilde{\rho} - \rho\|_\infty \geq \lambda/6) \leq p_n C \exp(-nc s^{-2} \lambda^2 \zeta^{-1})$ 。因为 $\|D\beta^*\|_\infty \leq sB\|D\|_{\max} \leq sB\|D\|_F$, 由引理4.2和假设 (A1) 的第一个式子可得, 对于 $\lambda \leq 12B\epsilon_0$, $P(sB\|D\|_F \geq \lambda/6) \leq p_n^2 C \exp(-nc p_n^{-2} s^{-2} \lambda^2 \zeta^{-1} B^{-2})$ 。对于 $\rho - \Sigma\beta^* = \frac{1}{n} X^T \varepsilon$ 是一个独立的亚高斯误差 ε 的线性组合, 且矩阵 X 的各列均被标准化了, 由定义4.1可得, $P(\|\rho - \Sigma\beta^*\|_\infty \geq \lambda/6) \leq p_n C \exp(-nc \lambda^2 \tau^{-2})$ 。重新定义 ζ 为先前的 ζ 与 τ^2 的最大值, 则有

$$\|\tilde{\rho} - \tilde{\Sigma}\beta^*\|_\infty < \lambda/2 \text{ 在 } \mathcal{F} \text{ 上成立, 其中 } P(\mathcal{F}) \geq 1 - p_n^2 C \exp(-nc s^{-2} \lambda^2 \zeta^{-1}).$$

接下来的证明, 将会限制 $\mathcal{F}$ 来调整 $\mathcal{F}^c$ 的概率。在 $\mathcal{F}$ 上, 重新考虑不等式 (4-38), 有

$$\frac{1}{2} \hat{v}^T \tilde{\Sigma} \hat{v} + \lambda \|\hat{\beta}\|_1 \leq \frac{\lambda}{2} \|\hat{v}\|_1 + \lambda \|\beta^*\|_1. \quad (4-40)$$

因为 $\beta_{S^c}^* = 0$, $\hat{v}_{S^c} = \hat{\beta}_{S^c}$, $\|\beta^*\|_1 = \|\beta_S^*\|_1$, 而且对任意的向量 x , 可以写成 $\|x\|_1 = \|x_S\|_1 + \|x_{S^c}\|_1$, 结合这些等式, 可以得到

$$\frac{1}{2} \hat{v}^T \tilde{\Sigma} \hat{v} + \lambda \|\hat{\beta}_S\|_1 + \lambda \|\hat{v}_{S^c}\|_1 \leq \frac{\lambda}{2} \|\hat{v}_S\|_1 + \frac{\lambda}{2} \|\hat{v}_{S^c}\|_1 + \lambda \|\beta_S^*\|_1. \quad (4-41)$$

由于 $\|\hat{\beta}_S\|_1 \geq \|\beta_S^*\|_1 - \|\hat{v}_S\|_1$, 从而

$$\hat{v}^T \tilde{\Sigma} \hat{v} + \lambda \|\hat{v}_{S^c}\|_1 \leq 3\lambda \|\hat{v}_S\|_1. \quad (4-42)$$

由于 $\hat{v}^T \tilde{\Sigma} \hat{v} > 0$, 因此在 $\mathcal{F}$ 上, 有 $\|\hat{v}_{S^c}\|_1 \leq 3\|\hat{v}_S\|_1$ 。于是, 根据假设 (A2) 可得, 在 $\mathcal{F}$ 上, $\|\hat{v}_{S^c}\|_1^2 \leq s \|\hat{v}\|^2 \leq s \hat{v}^T \tilde{\Sigma} \hat{v} / \Omega$ 。所以,

$$\begin{aligned} \hat{v}^T \Sigma \hat{v} + \lambda \|\hat{v}\|_1 &= \hat{v}^T \tilde{\Sigma} \hat{v} + \lambda \|\hat{v}_S\|_1 + \lambda \|\hat{v}_{S^c}\|_1 + \hat{v}^T D \hat{v} \\ &\leq 4\lambda \|\hat{v}_S\|_1 + \hat{v}^T D \hat{v} \quad \text{使用公式(4-42)} \\ &\leq 4\lambda \sqrt{s} \sqrt{\frac{\hat{v}^T \Sigma \hat{v}}{\Omega}} + \hat{v}^T D \hat{v} \quad \text{使用假设(A2)} \\ &\leq \frac{\hat{v}^T \Sigma \hat{v}}{4} + \frac{16\lambda^2 s}{\Omega} + |\hat{v}^T D \hat{v}| \quad \text{使用不等式 } 4ab \leq a^2/4 + 16b^2. \end{aligned} \quad (4-43)$$

上式右边的最后一项的界可以由如下式子确定

$$\begin{aligned} |\hat{v}^T D \hat{v}| &\leq \|D\|_{\max} \|\hat{v}\|_1^2 = \|D\|_{\max} (\|\hat{v}_S\|_1 + \|\hat{v}_{S^c}\|_1)^2 \leq 16\|D\|_F \|\hat{v}_S\|_1^2 \quad \text{在 } \mathcal{F} \text{ 上} \\ &\leq \|D\|_F \frac{s \hat{v}^T \Sigma \hat{v}}{\Omega} \quad \text{假设 (A2)}. \end{aligned} \quad (4-44)$$

根据引理4.2和假设 (A1), 对于 ε 小于某个常数 ϵ_0 , 有

$$P(16s\|D\|_F > \Omega/4) = P(\|D\|_F > \frac{\Omega}{64s}) \leq p_n^2 C \exp(-nc p_n^{-2} s^{-2} \varepsilon^2 \zeta^{-1}). \quad (4-45)$$

故, 如下式子成立的概率至少为 $1 - p_n^2 C \exp(-nc p_n^{-2} s^{-2} \varepsilon^2 \zeta^{-1}) - p_n^2 C \exp(-nc s^{-2} \lambda^2 \zeta^{-1})$,

$$\hat{v}^T \Sigma \hat{v} + \lambda \|\hat{v}\|_1 \leq \frac{\hat{v}^T \Sigma \hat{v}}{4} + \frac{16\lambda^2 s}{\Omega} + \frac{\hat{v}^T \Sigma \hat{v}}{4}, \quad (4-46)$$

化简不等式, 得

$$\frac{\hat{v}^T \Sigma \hat{v}}{2} + \lambda \|\hat{v}\|_1 \leq \frac{16\lambda^2 s}{\Omega}, \quad (4-47)$$

上述不等式可以得到定理4.1中的 l_1 误差和预测误差, 再结合 (A2) 假设中的 $\|\hat{v}\|^2 \leq$

$\hat{v}^T \Sigma \hat{v} / \Omega$ 可以得到 l_2 误差。

根据上述的证明，完成了定理4.1的证明。□

定理 4.2 的证明：(a) 令 $\hat{\beta}_S$ 为 Lasso 估计的解，即

$$\hat{\beta}_S = \arg \min_{\beta_S} \tilde{f}_S(\beta_S), \quad \text{其中 } \tilde{f}_S(\beta_S) = \frac{1}{2} \beta_S^T \tilde{\Sigma}_{S,S} \beta_S - \tilde{\rho}_S^T \beta_S + \lambda \|\beta_S\|_1. \quad (4-48)$$

令 $\hat{\beta} = (\hat{\beta}_S^T, 0_{(p_n-s) \times 1}^T)^T$, $\tilde{u} = (\tilde{u}_S^T, \tilde{u}_{S^c}^T)^T$, 其中 $\tilde{u}_S \in \partial(\|\hat{\beta}_S\|_1)$, $\tilde{u}_{S^c}$ 是某个未指定的 $(p_n - s) \times 1$ 维向量。由引理4.4的 (a) 可知，如果 $\hat{\beta}, \tilde{u}$ 满足：

$$\tilde{\Sigma}_{S,S} \hat{\beta}_S - \tilde{\rho}_S + \lambda \tilde{u}_S = 0, \quad (4-49)$$

$$\tilde{\Sigma}_{S^c,S} \hat{\beta}_S - \tilde{\rho}_{S^c} + \lambda \tilde{u}_{S^c} = 0,$$

则可知 $\hat{\beta}$ 是 (4-11) 的最优解。根据方程 (4-49)，求解 $\hat{\beta}_S$ 和 $\tilde{u}_{S^c}$ ，得

$$\hat{\beta}_S = \tilde{\Sigma}_{S,S}^{-1} (\tilde{\rho}_S - \lambda \tilde{u}_S), \quad \tilde{u}_{S^c} = \tilde{G} \tilde{u}_S + \frac{1}{\lambda} (\tilde{\rho}_{S^c} - \tilde{G} \tilde{\rho}_S). \quad (4-50)$$

根据引理4.4的 (b) 和 (c)，如果 $\tilde{\Sigma}_{S,S}$ 是非奇异的且 $\tilde{u}_{S^c}$ 所有分量的绝对值都小于 1，则 $\hat{\beta}$ 是 (4-11) 的唯一解。引理4.5给出了 $\Pr(\tilde{\Sigma}_{S,S} > 0)$ 的下界。接下来推导 $\Pr(\|\tilde{u}_{S^c}\|_\infty < 1)$ 的界。将 $\tilde{u}_{S^c}$ 展开成如下形式：

$$\begin{aligned} \tilde{u}_{S^c} &= G \tilde{u}_S + H \tilde{u}_S + \frac{1}{\lambda} ((\tilde{\rho}_{S^c} - \rho_{S^c}) + (\rho_{S^c} - G \rho_S) + G(\rho_S - \tilde{\rho}_S) - H \tilde{\rho}_S) \\ &= G \tilde{u}_S + H(\tilde{u}_S + \frac{1}{\lambda} ((\rho_S - \tilde{\rho}_S) - \frac{1}{\lambda} \rho_S)) \\ &\quad + \frac{1}{\lambda} ((\tilde{\rho}_{S^c} - \rho_{S^c}) + (\rho_{S^c} - G \rho_S) + G(\rho_S - \tilde{\rho}_S)). \end{aligned} \quad (4-51)$$

对上式取绝对值并使用三角不等式，可得：

$$\begin{aligned} \|\tilde{u}_{S^c}\|_\infty &\leq \|G \tilde{u}_S\|_\infty + \|H\|_\infty (1 + \frac{1}{\lambda} (\|\tilde{\rho}_S - \rho_S\|_\infty + \frac{1}{\lambda} \|\rho_S\|_\infty)) \\ &\quad + \frac{1}{\lambda} \|\rho_{S^c} - G \rho_S\|_\infty + (\frac{1}{\lambda} \|\tilde{\rho}_{S^c} - \rho_{S^c}\|_\infty + \frac{1}{\lambda} \|G(\rho_S - \tilde{\rho}_S)\|_\infty). \end{aligned} \quad (4-52)$$

分别对上述四项进行讨论。由假设 (A3) 可知， $\|G \tilde{u}_S\|_\infty < (1 - \gamma_1)$ ，由假设 (A1) 的第二个式子可以得到，对 $\lambda \leq 4\varepsilon_0/\gamma_1$ ，有

$$\begin{aligned} \Pr(\frac{1}{\lambda} \|\tilde{\rho}_{S^c} - \rho_{S^c}\|_\infty + \frac{1}{\lambda} \|G(\rho_S - \tilde{\rho}_S)\|_\infty < \gamma_1/2) &\geq \Pr(\frac{1}{\lambda} \|\tilde{\rho} - \rho\|_\infty < \gamma_1/4) \\ &\geq 1 - \delta_1(\lambda\gamma_1, \zeta). \end{aligned} \quad (4-53)$$

由于 $(\rho_{S^c} - G \rho_S) = \frac{1}{n} X_{S^c}^T (I - X_S (X_S^T X_S)^{-1} X_S^T) \varepsilon$ 是亚高斯随机变量的线性组合，因此根据定义4.1可得 $\Pr(\frac{1}{\lambda} \|\rho_{S^c} - G \rho_S\|_\infty \geq \gamma_1/4) \leq \delta_1(\lambda\gamma_1, \zeta)$ ，其中 ζ 重新定义为先前的 ζ 与 τ^2 的最大值。

不失一般性，假设 $\varepsilon_0 \leq 1$ ，则对 $\varepsilon \leq \min(1, \varepsilon_0)$ ，如下式子成立的概率至少为 $1 - \delta_1(\varepsilon, \zeta)$ ，

$$\|\tilde{\rho}_S - \rho_S\|_\infty + \|\rho_S\|_\infty \leq \|\tilde{\rho}_S - \rho_S\|_\infty + \|\frac{1}{n} X_S^T \varepsilon\|_\infty + \|\frac{1}{n} X_S^T X_S \beta_S^*\|_\infty \leq 2 + B\psi. \quad (4-54)$$

结合这些式子并使用引理4.6，可得如下式子成立的概率至少为 $1 - \delta_2(\varepsilon, \zeta)$ ：对于

$$\varepsilon \leq \varepsilon_0^*, \quad \varepsilon_0^* = \min(\varepsilon_0^*, \gamma_1 \lambda \phi^{-1} (8(2 - \gamma_1)(\lambda + 2 + B\psi) + \gamma_1 \lambda)^{-1}),$$

$$\|H\|_\infty (1 + \frac{1}{\lambda} (\|\tilde{\rho}_S - \rho_S\|_\infty + \frac{1}{\lambda} \|\rho_S\|_\infty)) \leq (1 + \frac{1}{\lambda} (2 + B\psi)) \frac{\varepsilon \phi (2 - \gamma_1)}{1 - \phi \varepsilon} \leq \frac{\gamma_1}{8}. \quad (4-55)$$

结合所有的概率，并对可逆性概率进行调整，则对 $\lambda \leq 4\varepsilon_0/\gamma_1$ 且 $\varepsilon \leq \min(\varepsilon_0^*, C_{\min}/2)$ ，有 $\Pr(\|\tilde{u}_{S^c}\|_\infty \geq 1 - \gamma_1/8) \leq \delta_1(\lambda\gamma_1, \zeta) + \delta_2(\varepsilon, \zeta)$ 。

这就完成了定理4.2(a)部分的证明。□

下面对定理4.2的 (b) 和 (c) 部分进行证明。

利用 (4-50) 中的 $\hat{\beta}_S$ 的表达式，并将其展开成如下形式：

$$\begin{aligned} \hat{\beta}_S - \beta_S^* &= \tilde{\Sigma}_{S,S}^{-1} (\tilde{\rho}_S - \rho_S + \frac{1}{n} X_S^T X_S \beta_S^* + \frac{1}{n} X_S^T \varepsilon - \lambda \tilde{u}_S) - \beta_S^* \\ &= F_{S,S} (\tilde{\rho}_S - \rho_S + \frac{1}{n} X_S^T X_S \beta_S^* + \frac{1}{n} X_S^T \varepsilon) \\ &\quad + \Sigma_{S,S}^{-1} (\tilde{\rho}_S - \rho_S) + \frac{1}{n} \Sigma_{S,S}^{-1} X_S^T \varepsilon - \lambda \tilde{\Sigma}_{S,S}^{-1} \tilde{u}_S. \end{aligned} \quad (4-56)$$

分别对上述每一项进行讨论，注意到 $\frac{1}{n} \Sigma_{S,S}^{-1} X_S^T \varepsilon$ 是服从参数至多为 $\sigma^2 C_{\min}/n$ 的亚高斯随机向量，从而由定义4.1可知， $\Pr(\|\frac{1}{n} \Sigma_{S,S}^{-1} X_S^T \varepsilon\|_\infty < \lambda \sqrt{C_{\min}}) \geq 1 - \delta_1(\lambda, \zeta)$ 。此外，由于 $\tilde{\Sigma} = \Sigma + F$ ，根据引理4.6知，对于 $\varepsilon \leq \min(\varepsilon_0, (2\phi)^{-1})$ ，如下式子成立的概率至少为 $1 - \delta_2(\varepsilon, \zeta)$ ：

$$\|\tilde{\Sigma}_{S,S}\|_\infty \leq \phi + \phi^2 \varepsilon (1 - \phi \varepsilon)^{-1} \leq 2\phi. \quad (4-57)$$

根据假设 (A1) 的第二个式子，对于 $\lambda \leq \varepsilon_0$ ，有 $\Pr(\|\tilde{\rho}_S - \rho_S\|_\infty \leq \lambda) \geq 1 - \delta_1(\lambda, \zeta)$ 。根据 (a) 部分的证明，同样可以得到如下结论：对于 $\varepsilon \leq \varepsilon_0$ ， $\|\tilde{\rho}_S - \rho_S\|_\infty + \|\frac{1}{n} X_S^T X_S \beta_S^*\|_\infty + \|\frac{1}{n} X_S^T \varepsilon\|_\infty \leq (2 + B\psi)$ 成立的概率至少为 $1 - \delta_2(\varepsilon, \zeta)$ 。因此，对于 $\varepsilon \leq \lambda \phi^{-1} (\lambda + 2 + B\psi)^{-1}$ ， $\|F_{S,S} (\tilde{\rho}_S - \rho_S + \frac{1}{n} X_S^T X_S \beta_S^* + \frac{1}{n} X_S^T \varepsilon)\|_\infty < (2 + B\psi) \frac{\phi^2 \varepsilon}{1 - \phi \varepsilon} \leq \lambda \phi$ 成立的概率至少为 $1 - \delta_2(\varepsilon, \zeta)$ 。对所有的概率进行整合，则对 $\varepsilon \leq \min(\varepsilon_0, C_{\min}/2, (2\phi)^{-1}, \lambda \phi^{-1} (\lambda + 2 + B\psi)^{-1})$ 且 $\lambda \leq \varepsilon_0$ ，有如下式子成立的概率至少为 $1 - \delta_1(\lambda, \zeta) - \delta_2(\varepsilon, \zeta)$ ，

$$\begin{aligned} \|\hat{\beta}_S - \beta_S^*\|_\infty &\leq \|F_{S,S} (\tilde{\rho}_S - \rho_S + \frac{1}{n} X_S^T X_S \beta_S^* + \frac{1}{n} X_S^T \varepsilon)\|_\infty \\ &\quad + \phi \|\tilde{\rho}_S - \rho_S\|_\infty + \|\frac{1}{n} \Sigma_{S,S}^{-1} X_S^T \varepsilon\|_\infty + 2\lambda \phi \\ &\leq \lambda (4\phi + \frac{1}{\sqrt{C_{\min}}}). \end{aligned} \quad (4-58)$$

这就完成了 (b) 部分的证明。因此，如果 $|\beta_{\min}^*| > \lambda (4\phi + \frac{1}{\sqrt{C_{\min}}})$ ，则根据 Lasso 估计器的符号一致性可以轻易证明定理4.2的 (c) 部分。

根据上述的证明，对定理4.2完成了证明。□

定理 4.3的证明： 令 $\gamma_n = \sqrt{p_n}(n^{-1/2} + a_n)$ ， $\|u\| = C$ ，其中 C 是一个足够大的常数。目标是证明对于任意给定的 ε ，都有一个足够大的常数 C ，使得对于较大的 n ，有

$$P\{\inf_{\|u\|=C} Q_n(\beta^* + \gamma_n u) > Q_n(\beta^*)\} \geq 1 - \varepsilon.$$

这意味着, 在 $\{\beta^* + \gamma_n u : \|u\| \leq C\}$ 中存在一个局部最小值 $\hat{\beta}$ 使得 $\|\hat{\beta} - \beta^*\| = O_p(\gamma_n)$ 成立的概率趋于 1。

利用 $p_\lambda(0) = 0$, 得

$$\begin{aligned} D_n(u) &= Q_n(\beta^* + \gamma_n u) - Q_n(\beta^*) \\ &\geq \frac{\gamma_n^2}{2} u^T \tilde{\Sigma} u + \gamma_n u^T (\tilde{\Sigma} \beta^* - \tilde{\rho}) \\ &\quad + \sum_{j=1}^s \{p_\lambda(|\beta_j^* + \gamma_n u_j|) - p_\lambda(|\beta_j^*|)\} \\ &\triangleq D_{n,I}(u) + D_{n,II}(u), \end{aligned} \quad (4-59)$$

其中, β_j^* 是 β^* 的第 j 个分量, s 是 β_s^* 元素的个数。对 $D_{n,II}(u)$ 使用泰勒展开, 得

$$\begin{aligned} D_{n,II}(u) &= \sum_{j=1}^s [\gamma_n p'_\lambda(|\beta_j^*|) \text{sgn}(\beta_j^*) u_j + \frac{\gamma_n^2}{2} p''_\lambda(|\beta_j^*|) u_j^2 \{1 + o(1)\}] \\ &\leq \sum_{j=1}^s [|\gamma_n p'_\lambda(|\beta_j^*|) \text{sgn}(\beta_j^*) u_j| + \frac{\gamma_n^2}{2} p''_\lambda(|\beta_j^*|) u_j^2 \{1 + o(1)\}] \\ &\leq \sqrt{s} \gamma_n a_n \|u\| + \max_{1 \leq j \leq s} p''_\lambda(|\beta_j^*|) \gamma_n^2 \|u\|^2 \\ &\leq \gamma_n^2 \|u\| + b_n \gamma_n^2 \|u\|^2. \end{aligned} \quad (4-60)$$

下面对 $D_{n,I}(u)$ 的每一项进行讨论。当 n 足够大时, 由假设 (A1) 得 $\hat{\Sigma} - \Sigma = o_p(1)$, $\tilde{\rho} - \rho = o_p(1)$ 。根据 F 范数和 $\tilde{\Sigma}$ 的定义, 有 $|\tilde{\Sigma}_{ij} - \hat{\Sigma}_{ij}| \leq \|\tilde{\Sigma} - \hat{\Sigma}\|_F \leq \|\hat{\Sigma} - \Sigma\|_F$, 从而由假设 (A1), 引理 4.2 及条件 $n \rightarrow \infty$ 时, $p_n^2/n \rightarrow 0$, 可得:

$$P(|\tilde{\Sigma}_{ij} - \hat{\Sigma}_{ij}| \geq \varepsilon) \leq P(\|\hat{\Sigma} - \Sigma\|_F \geq \varepsilon) \leq p_n^2 C \exp(-cn p_n^{-2} \varepsilon^2 \zeta^{-1}) \rightarrow 0. \quad (4-61)$$

于是有 $\tilde{\Sigma} - \hat{\Sigma} = o_p(1)$, 从而 $\tilde{\Sigma} - \Sigma = o_p(1)$ 。根据假设 (A4), 以及条件 $n \rightarrow \infty$ 时, $p_n^2/n \rightarrow 0$, 可得:

$$\begin{aligned} \frac{\gamma_n^2}{2} u^T \tilde{\Sigma} u &= \frac{\gamma_n^2}{2} u^T (\tilde{\Sigma} - \Sigma) u + \frac{\gamma_n^2}{2} u^T \Sigma u \\ &\leq \frac{\gamma_n^2}{2} u^T \Sigma u + o_p(\gamma_n^2/2) \|u\|^2 \\ &\triangleq I_1 + o_p(\gamma_n^2/2) \|u\|^2. \end{aligned} \quad (4-62)$$

考虑 I_1 项,

$$|I_1| = \frac{\gamma_n^2}{2} u^T (\Sigma - E(X^T X)) u + \frac{\gamma_n^2}{2} u^T E(X^T X) u, \quad (4-63)$$

易知

$$P(\|\Sigma - E(X^T X)\| \geq \varepsilon) \leq \frac{n}{n^2 \varepsilon^2} E \sum_{i,j}^{p_n} \{X_i X_j - E(X_i X_j)\}^2 = p_n^2/n, \quad (4-64)$$

由条件 $n \rightarrow \infty$ 时, $p_n^2/n \rightarrow 0$, 可得:

$$\|\Sigma - E(X^T X)\| = O_p(p_n/\sqrt{n}) = o_p(1). \quad (4-65)$$

因此, $|\frac{\gamma_n^2}{2} u^T \tilde{\Sigma} u| = \frac{\gamma_n^2}{2} u^T E(X^T X) u + o_p(\gamma_n^2/2) \|u\|^2$ 。

对于 $D_{n,l}(u)$ 的第二项, 可将其写成如下形式:

$$|\gamma_n u^T(\tilde{\Sigma}\beta^* - \tilde{\rho})| \leq \gamma_n \|u\|_1 \|\tilde{\Sigma}\beta^* - \tilde{\rho}\|_\infty \leq \gamma_n p_n \|\tilde{\Sigma}\beta^* - \tilde{\rho}\|_\infty \|u\|. \quad (4-66)$$

由于 $\|\tilde{\Sigma}\beta^* - \tilde{\rho}\|_\infty \leq \|(\tilde{\Sigma} - \Sigma)\beta^*\|_\infty + \|\Sigma\beta^* - \rho\|_\infty + \|\rho - \tilde{\rho}\|_\infty$, 使用假设 (A1), 以及条件 $n \rightarrow \infty$ 时, $p_n^2/n \rightarrow 0$, 并根据定理4.1中的证明可知:

$$P(\|\tilde{\Sigma}\beta^* - \tilde{\rho}\|_\infty \geq \varepsilon) \leq p_n^2 C \exp(-nc p_n^{-2} s^{-2} \varepsilon^2 \zeta^{-1}) \rightarrow 0. \quad (4-67)$$

从而有, $|\gamma_n u^T(\tilde{\Sigma}\beta^* - \tilde{\rho})| = o_p(p_n^{1/2} \gamma_n^2) \|u\|$.

综合以上所有结果, 只要 C 充分大, 那么 $\frac{\gamma_n^2}{2} u^T \tilde{\Sigma} u$ 在 $\|u\| = C$ 条件下, 由于 $\frac{\gamma_n^2}{2} u^T \tilde{\Sigma} u$ 是正定的, 则该项会一致地为最大项。

根据上面的证明, 完成了定理4.3的证明。□

定理4.4的证明: 先对稀疏性进行证明。由定理4.3知, 对于充分大的 C , 且在 $\{\beta^* + \gamma_n u : \|u\| \leq C\}$ 中存在 β 的概率趋于 1 (当 $n \rightarrow \infty$ 时), 其中 $\gamma_n = \sqrt{p_n}(n^{-1/2} + a_n)$ 。考虑 $Q_n(\beta)$ 在 β_j , $j = s+1, s+2, \dots, p_n$ 的偏导:

$$\begin{aligned} \frac{\partial Q_n(\beta)}{\partial \beta_j} &= -\tilde{\rho}_j + \tilde{\Sigma}_j^T \beta + p'_\lambda(|\beta_j|) \text{sgn}(\beta_j) \\ &= -(\tilde{\rho}_j - \rho_j) - (\rho_j - \Sigma_j^T \beta^*) + \Sigma_j^T (\beta - \beta^*) \\ &\quad + (\tilde{\Sigma}_j^T - \Sigma_j^T) \beta + p'_\lambda(|\beta_j|) \text{sgn}(\beta_j). \end{aligned} \quad (4-68)$$

根据定理4.3, 对任意的 $\beta = (\beta_S^T, \beta_{S^c}^T)^T$, 都满足 $\beta_S - \beta_S^* = O_p(\sqrt{p_n/n})$ 且 $|\beta_{S^c} - \beta_{S^c}^*| \leq \varepsilon_n = C \sqrt{p_n/n}$ 。注意到 $\rho_j - \Sigma_j^T \beta^* = \frac{1}{n} X_j^T Y - \frac{1}{n} X_j^T X \beta^* = \frac{1}{n} X_j^T \varepsilon = \frac{1}{n} \sum_{i=1}^n \varepsilon_i X_{ij}$, $\Sigma_j(\beta - \beta^*) = \frac{1}{n} \sum_{i=1}^n X_i^T (\beta - \beta^*) X_{ij}$, 容易证明

$$E\left(\max_{k_n+1 \leq j \leq p_n} \left| \sum_{i=1}^n \varepsilon_i X_{ij} \right| \right) \leq E^{1/2} \left(\sum_{j=s+1}^{p_n} \left| \sum_{i=1}^n \varepsilon_i X_{ij} \right|^2 \right) \leq \sigma \sqrt{n p_n}, \quad (4-69)$$

$$\begin{aligned} \max_{k_n+1 \leq j \leq p_n} \left| \sum_{i=1}^n X_i^T (\beta - \beta^*) X_{ij} \right| &\leq \|\beta - \beta_0\| \max_{s+1 \leq j \leq p_n} \sqrt{X_j^T X X_j} \\ &\leq C \sqrt{p_n/n} \max_{s+1 \leq j \leq p_n} \|X_{\cdot j}\| \Lambda_{\max}^{1/2}(X^T X) \\ &= O_p(\sqrt{n p_n}). \end{aligned} \quad (4-70)$$

根据假设 (A1) 可以证明 $\tilde{\rho}_j - \rho_j = o_p(1)$, $(\tilde{\Sigma}_j^T - \Sigma_j^T) \beta = o_p(1)$ 。结合上述所有结论, 并注意到 $\sqrt{p_n/n} \lambda \rightarrow 0$ 且 $\liminf_{n \rightarrow \infty} \liminf_{\theta \rightarrow 0+} p'_\lambda(\theta)/\lambda > 0$, 则有

$$\frac{\partial Q_n(\beta)}{\partial \beta_j} = \lambda \{-O_p(\sqrt{p_n/n}/\lambda) + \frac{p'_\lambda(|\beta_j|)}{\lambda} \text{sgn}(\beta_j)\}. \quad (4-71)$$

显然, β_j 的符号决定了 $\frac{\partial Q_n(\beta)}{\partial \beta_j}$ 的符号。因此, 式 (4-71) 意味着

$$\frac{\partial Q_n(\beta)}{\partial \beta_j} = \begin{cases} > 0, & 0 < \beta_j < \varepsilon_n. \\ < 0, & -\varepsilon_n < \beta_j < 0. \end{cases} \quad (4-72)$$

其中, $j = s+1, s+2, \dots, p_n$ 。这就完成了稀疏性的证明。

下面证明渐近正态性。如定理4.3所示, $\hat{\beta}$ 是根 (n/p_n) 一致的, 在稀疏性的证

明中, 只要 n 足够大, $\hat{\beta}_S$ 的分量均不为零, $\hat{\beta}_{S^c} = 0$ 的概率趋于 1。因此, 由于概率趋于 1, 则前 s 个分量存在偏导数。为方便起见, 令 $Q_n(\beta_S) = Q_n(\beta_S, \beta_{S^c})$ 。由于 $\nabla Q_n(\hat{\beta}_S) = 0$, 对 $\nabla Q_n(\hat{\beta}_S)$ 在 β_S^* 处使用泰勒展开, 得:

$$\nabla Q_n(\hat{\beta}_S) = \nabla Q_n(\beta_S^*) + \nabla^2 Q_n(\beta_S^{**})(\hat{\beta}_S - \beta_S^*) \quad (4-73)$$

其中, β_S^{**} 位于 $\hat{\beta}_S$ 和 β_S^* 之间。将上述式子展开可得:

$$(\tilde{\Sigma}_{S,S} + \nabla^2 p_\lambda(|\beta_S^{**}|))(\hat{\beta}_S - \beta_S^*) + \nabla p_\lambda(|\beta_S^{**}|) = \tilde{\rho}_S - \tilde{\Sigma}_{S,S}\beta_S^*. \quad (4-74)$$

其中, $\nabla p_\lambda(|\beta_S^{**}|)$ 是 $s \times 1$ 维向量, 第 j 个元素为 $p'_\lambda(|\beta_j^{**}|)\text{sgn}(\beta_j^{**})$; $\nabla^2 p_\lambda(|\beta_S^{**}|)$ 是对角元素为 $p''_\lambda(|\beta_j^{**}|)(j = 1, 2, \dots, s)$ 的对角矩阵。当 n 足够大时, $\tilde{\Sigma} - \hat{\Sigma} = o_p(1)$ 。

与 Xu^[44] 一文中的定理 2.2 的证明类似, 可以由条件 $n \rightarrow \infty$ 时, $p_n^2/n \rightarrow 0$, 得到:

$$\sqrt{n}[\tilde{\rho}_S - \hat{\Sigma}_{S,S}\beta_S^* - (\tilde{\Sigma}_{S,S} - \hat{\Sigma}_{S,S})\beta_S^*] \rightarrow N(0, \Sigma_{S,S}^2). \quad (4-75)$$

因此, 使用 Slutsky 定理, 由条件 $n \rightarrow \infty$ 时, $p_n^2/n \rightarrow 0$, 可以得出:

$$\sqrt{n}(\Sigma_{S,S}^1 + \Sigma_\lambda(\beta_S^*))[\hat{\beta}_S - \beta_S^* + (\Sigma_{S,S}^1 + \Sigma_\lambda(\beta_S^*))^{-1}B_n] \rightarrow N(0, \Sigma_{S,S}^2). \quad (4-76)$$

这就完成了渐近正态性的证明。

根据上述的证明, 完成了定理 4.4 的证明。□

第5章 带可加扭曲测量误差的高维线性模型的变量选择和参数估计

在上一章中, 由于 Classical 测量误差服从正态分布的假设会限制模型的应用。同时, 无论是预测变量, 还是响应变量, 得到的观测值都可能存在着不是真实值的情况。因此, 在本章中考虑一般化的测量误差, 即扭曲测量误差, 并对高维线性模型中变量存在可加扭曲测量误差时的变量选择和参数估计进行研究。首先, 使用核密度估计法对扭曲函数的分布进行估计, 从而恢复了不能被直接观测得到的预测变量和响应变量。基于恢复后的数据, 采用 Lasso 惩罚最小二乘法构建目标函数; 此外还将 SCAD 惩罚函数与该方法进行了结合。其次, 借助坐标下降法对目标函数进行了求解。最后, 利用 Monte Carlo 数值模拟验证了提出的方法的有效性, 并将与 SCAD 惩罚函数结合的方法应用在 Boston housing 数据实例分析中。

5.1 符号与模型

带可加扭曲测量误差的高维线性模型如下:

$$\begin{cases} Y = X\beta + \varepsilon, \\ \tilde{Y}_i = Y_i + \phi(U_i), \quad i = 1, 2, \dots, n. \\ \tilde{X}_{ir} = X_{ir} + \psi_r(U_i), \quad r = 1, 2, \dots, p_n. \end{cases} \quad (5-1)$$

其中, $Y = (Y_1, Y_2, \dots, Y_n)^T$ 为响应变量, $X = (X_{ir})_{n \times p_n}$ 为预测变量, 均是真值且不可被观测的; $\tilde{Y}$ 和 $\tilde{X}$ 是相应的观测值; $\phi(\cdot)$ 和 $\psi_r(\cdot)$ 是观测到的混杂变量 U 的扭曲函数。

为了识别模型 (5-1) 的未知参数, 需要对未知的, 光滑的扭曲函数进行以下约束:

$$E[\phi(U)] = 0, \quad E[\psi_r(U)] = 0, \quad r = 1, \dots, p_n. \quad (5-2)$$

不失一般性, 假设变量 U 与 Y, X 是相互独立的, 并且 ε 满足 $E(\varepsilon) = 0$, $\text{Var}(\varepsilon) = \tau^2$ 。

5.2 参数估计

本节采用核密度估计法恢复不能被直接观测的预测变量和响应变量。基于恢复后的数据，分别使用 Lasso 和 SCAD 惩罚最小二乘法构建目标函数，并借助坐标下降法对目标函数进行求解，得到参数估计值，同时达到变量选择的效果。

5.2.1 核密度估计法

在模型 (5-1) 中，真实数据 (Y_i, X_i) 是不可被直接观测得到的。为了能够得到模型参数的估计值，需要通过可观测的数据 $(\tilde{Y}_i, \tilde{X}_i = (\tilde{X}_{i1}, \tilde{X}_{i2}, \dots, \tilde{X}_{ip_n}), U_i, 1 \leq i \leq n)$ 估计出不可观测的数据 (Y_i, X_i) ，记其估计值为 $(\hat{Y}_i, \hat{X}_i)$ 。

由模型的可识别条件 (5-2) 及 U 与 Y, X 是相互独立的，可得：

$$\phi(U) = E[\tilde{Y}|U] - E[\tilde{Y}], \quad \psi_r(U) = E[\tilde{X}_r|U] - E[\tilde{X}_r], \quad r = 1, \dots, p_n. \quad (5-3)$$

根据 Cui^[47] 等研究方法的思路，及式 (5-3)，可以使用数据 $(\tilde{Y}_i, \tilde{X}_i, U_i, 1 \leq i \leq n)$ 估计出 $\phi(U)$ 和 $\psi_r(U) (1 \leq r \leq p_n)$ ，计算公式如下：

$$\begin{aligned} \hat{\phi}(U) &= \frac{\frac{1}{n} \sum_{i=1}^n K_{h_y}(u - U_i) \tilde{Y}_i}{\frac{1}{n} \sum_{i=1}^n K_{h_y}(u - U_i)} - \bar{\tilde{Y}}, \\ \hat{\psi}_r(U) &= \frac{\frac{1}{n} \sum_{i=1}^n K_{h_r}(u - U_i) \tilde{X}_{ir}}{\frac{1}{n} \sum_{i=1}^n K_{h_r}(u - U_i)} - \bar{\tilde{X}}_r, \quad r = 1, \dots, p_n. \end{aligned} \quad (5-4)$$

其中， $K_{h_y}(\cdot) = K(\cdot/h_y)$ ， $K_{h_r}(\cdot) = K(\cdot/h_r)$ ， $K(\cdot)$ 是核密度函数， h_y 和 h_r 是窗宽， $\bar{\tilde{Y}} = \frac{1}{n} \sum_{i=1}^n \tilde{Y}_i$ ， $\bar{\tilde{X}}_r = \frac{1}{n} \sum_{i=1}^n \tilde{X}_{ir}$ 。

在模型 (5-1) 的第二和第三个等式中，用 $\hat{\phi}(U)$ 和 $\hat{\psi}_r(U)$ 替换 $\phi(U)$ 和 $\psi_r(U)$ ，然后就可以得到恢复的数据 $(\hat{Y}_i, \hat{X}_i), 1 \leq i \leq n$ ，其中 $\hat{Y}_i = \tilde{Y}_i - \hat{\phi}(U_i)$ ， $\hat{X}_{ir} = \tilde{X}_{ir} - \hat{\psi}_r(U_i)$ 。

5.2.2 惩罚最小二乘法

在 5.2.1 小节中，已经得到了恢复的数据 $(\hat{Y}_i, \hat{X}_i, 1 \leq i \leq n)$ 。基于此数据，采用惩罚最小二乘法来构建求解模型参数的目标函数。

使用 Lasso 惩罚函数，则估计模型 (5-1) 的未知参数是通过最小化如下目标函数：

$$Q_n(\beta; \lambda) = \frac{1}{2} \sum_{i=1}^n (\hat{Y}_i - \hat{X}_i \beta)^2 + n \sum_{j=1}^p \lambda |\beta_j|. \quad (5-5)$$

如果采用 SCAD 惩罚函数，则相应的目标函数为：

$$Q_n(\beta; \lambda, \gamma) = \frac{1}{2} \sum_{i=1}^n (\hat{Y}_i - \hat{X}_i \beta)^2 + n \sum_{j=1}^p p_\lambda(|\beta_j|), \quad (5-6)$$

其中， $p_\lambda(\cdot)$ 为 SCAD 惩罚函数，定义可见 4.2.2 节； λ 为调优参数，通常采用交叉验证法来选择； $\gamma = 3.7$ 为另一个调优参数，这是由文献 Fan 和 Li^[24] 得到的。

对于目标函数 (5-5) 的求解, 采用坐标下降法; 而对于目标函数 (5-6) 的求解, 由于 $Q_n(\beta; \lambda, \gamma)$ 在原点处不可导, 通常使用局部二次近似的迭代算法来求解。但是, 在第4.2.2小节中提到, 坐标下降法同样适用非凸惩罚函数的变量选择方法。因此, 仍然采用坐标下降法来求解目标函数 (5-6), 并在后续的 Monte Carlo 模拟中与局部二次近似迭代算法进行比较。

5.2.3 窗宽及调优参数的选择

在5.2.2小节求解算法的计算过程中, 需要事先给定窗宽以及调优参数。惩罚估计与窗宽和调优参数之间有着密切的联系, 合适的窗宽能够使得恢复的数据更接近真实数据, 而合适的调优参数能够使得模型参数估计和变量选择的效果更优。

关于恢复真实数据集 $(Y_i, X_i, 1 \leq i \leq n)$ 的过程中窗宽的选择, 采用 Feng^[48] 使用的广义交叉验证 GCV 方法。下面以恢复 Y 的估计过程中使用的窗宽 h_y 为例进行说明, 记 $\tilde{Y} = \frac{1}{n} \sum_{i=1}^n \tilde{Y}_i$, $\hat{Y}_i = \hat{\phi}(U_i) + \tilde{Y}$, $\hat{Y} = (\hat{Y}_1, \dots, \hat{Y}_n)^T$, $\tilde{Y} = (\tilde{Y}_1, \dots, \tilde{Y}_n)^T$, $V = (V_1, \dots, V_n)^T$, $V_j = (V_{j1}, \dots, V_{jn})^T$, $V_{jk} = \frac{K_h((U_j - U_k))}{\sum_{k=1}^n K_h((U_j - U_k))}$, $(j, k = 1, \dots, n)$, 则可知 $\hat{Y} = V\tilde{Y}$ 。从而 GCV 准则可以表示成如下形式:

$$\text{GCV}(h) = \frac{n^{-1} \text{RSS}(h)}{(1 - \text{tr}(V)/n)^2}, \quad (5-7)$$

其中, $\text{RSS}(h) = \|\hat{Y} - \tilde{Y}\|^2$ 表示残差平方和, $\text{tr}(V)$ 表示矩阵 V 的迹。使得 $\text{GCV}(h)$ 取得最小值时的 h 即为最优的窗宽。类似地, 其它的窗宽也按照此方法选择。

关于调优参数 λ 的选择, 采用交叉验证法。下面以 K 折交叉验证法为例进行说明, 令 $(\hat{Y}_k, \hat{X}_k)(k = 1, 2, \dots, K)$ 为第 k 个子集相应变量的数据, $(\hat{Y}_{(-k)}, \hat{X}_{(-k)})$ 表示去除第 k 个子集后剩余的数据, 则最优的 λ 是通过最小化如下目标函数:

$$\hat{\lambda} = \arg \min_{\lambda} \frac{1}{K} \sum_{k=1}^K \frac{1}{n_k} \|\hat{Y}_k - \hat{X}_k \hat{\beta}_k(\lambda)\|^2, \quad (5-8)$$

其中, $\hat{\beta}_k(\lambda)$ 是在数据为 $(\hat{Y}_{(-k)}, \hat{X}_{(-k)})$, 调优参数为 λ 时的参数估计值, n_k 为第 k 个子集的数据样本量。

对于式 (5-8), 进行简单的代数运算, 等价于如下形式:

$$\hat{\lambda} = \arg \min_{\lambda} \sum_{k=1}^K \hat{\beta}_k(\lambda)^T \hat{\Sigma}_k \hat{\beta}_k(\lambda) - 2 \tilde{\rho}_k^T \hat{\beta}_k(\lambda), \quad (5-9)$$

其中, $\hat{\Sigma}_k = \frac{1}{n_k} \hat{X}_k^T \hat{X}_k$, $\tilde{\rho}_k = \frac{1}{n_k} \hat{X}_k^T \hat{Y}_k$ 。

5.3 重采样方法

Jin 等人^[49]提出了重采样方法来估计极限协方差矩阵,且该方法不涉及非参数密度估计或数值导数。Li 等人^[36]在对协变量调整回归模型的研究中,采用此方法来估计渐近协方差矩阵。因此,我们同样使用此方法来近似渐近协方差矩阵。具体来说,将 $\hat{\beta}^*$ 定义为如下扰动损失函数的最小值:

$$Q_n^*(\beta^*; \lambda, \gamma) = \frac{1}{2} \sum_{i=1}^n W_i (\hat{Y}_i - \hat{X}_i \beta^*)^2 + n \sum_{j=1}^p p_\lambda(|\beta_j|), \quad (5-10)$$

其中, $W_i (i = 1, \dots, n)$ 为独立的、正的随机变量,且满足 $E(W_i) = 1$ 和 $\text{Var}(W_i) = 1$ 。同时,与观测数据 $(\tilde{Y}_i, \tilde{X}_i = (\tilde{X}_{i1}, \tilde{X}_{i2}, \dots, \tilde{X}_{ip_n}), U_i, 1 \leq i \leq n)$ 独立。

在观测数据的条件下, $Q_n^*(\beta^*; \lambda, \gamma)$ 中唯一的随机变量就是 W_i 。因此,只要通过重复生成随机样本 $(W_1, \dots, W_n)$, 就可以得到大量的 $\hat{\beta}^*$, 计算出 $\hat{\beta}^*$ 的经验协方差矩阵,从而可以得到渐近协方差矩阵的近似矩阵。有关此方法的详细信息可以参考相关文献^{[49][50]}。

5.4 Monte Carlo 数值模拟

本节使用 Monte Carlo 数值模拟来验证本章所提出的方法在有限样本下的变量选择和参数估计的效果。简单起见,将5.2.2小节中描述的两种方法分布记为 Lasso 和 SCAD。为了进行比较,将提出的方法与其它几种普遍方法进行对比,包括 Oracle(即扭曲测量误差不存在,观测值为真值)和 LQA-SCAD(目标函数(5-6)的求解方法为局部二次近似迭代算法)。对于每一种方法,同样使用4.4节中的指标 C、IC 和 SE 来评估变量选择和参数估计的效果。

模拟的模型为:

$$\begin{cases} Y = X\beta + \varepsilon, \\ \tilde{Y} = Y + \phi(U), \\ \tilde{X}_r = X_r + \psi_r(U), \quad r = 1, \dots, p_n. \end{cases} \quad (5-11)$$

其中, $X = (X_1, \dots, X_{p_n})$, $\beta = (\beta_1, \dots, \beta_{p_n})^T$ 且满足 $\beta_1 = \beta_2 = \beta_3 = 1$, $\beta_l = 0 (l = 4, \dots, p_n)$, 随机误差项 $\varepsilon \sim N(0, \tau^2)$ 。 U 服从正态分布 $N(6, 1)$, X 服从多元正态分布, X_r 和扭曲函数 $\phi(U)$, $\psi_r(U)$, $r = 1, \dots, p_n$, 满足以下条件:

$$X_r \sim N(0, 1), \quad \phi(U) = (U - 6)/3, \quad \psi_1(U) = (U - 6)/16,$$

$$\psi_2(U) = (U + 1)^2 - 50, \quad \psi_3(U) = (U - 1)^2 - 26,$$

$$\psi_4(U) = (U + 2)^2 - 65, \quad \psi_5(U) = (U - 6)/7,$$

$$\psi_l(U) = (U - 6)/3, \quad l = 6, \dots, p_n.$$

上述所有扭曲函数均满足可识别条件 (5-2)。

在数据恢复过程中, 根据5.2.3小节中的方法选择最优的窗宽, 其中所使用的核密度函数为 $K(u) = 3/4(1 - u^2)I(|u| \leq 1)$ 。同时, 使用五折交叉验证法选择调优参数 λ 。

为了进一步比较, 还考虑了 τ 的三个不同值, 分别为 0.1, 0.5 和 1, 代表着噪声水平的强弱程度, 以及不同的样本量 n 和不同的预测变量数量 p_n , 并在每个模拟中, 进行了 100 次 Monte Carlo 模拟。模拟的结果呈现在表5-1中, 此表中的 C、IC 和 SE 三种指标均为平均值。

表5-1展示了每一种方法的变量选择效果以及参数估计误差, 但是没有展示各个参数具体的估计值。因此, 为了更好地观察每一种方法得到的参数估计值, 从 $(n, p_n, \tau) = (200, 400, 0.1)$ 中列出了一次模拟的具体参数估计值, 见表5-2, 此表中未给出值的均为零。此外, 以模拟 $(n, p_n) = (200, 400)$ 为例, 图5-1呈现了 SCAD 和 LQA-SCAD 这两种方法的 100 次模拟结果, 由于指标 C 的所有模拟结果均为 3, 故未在图中呈现。

从表5-1和5-2, 以及图5-1中, 可以得到如下结论: (1) 在使用 SCAD 惩罚函数的前提下, 对于模型未知参数的求解方法, 使用局部二次近似法和使用坐标下降法相比, 两种方法得到的参数估计误差相差不大, 但后者的变量选择效果却要优于前者。(2) 随着样本量 n 的增加或者噪声水平 τ 的减小, 无论是 Lasso 方法还是 SCAD 方法, 它们的估计误差均在不断地减小, 但是 SCAD 方法得到的参数估计值有着更小的偏差, 且更接近真实值。这表明 SCAD 方法在估计误差方面比 Lasso 方法更优。(3) 对于重要变量, Lasso 和 SCAD 方法均能正确识别; 对于无关变量, SCAD 方法选择的数量总是少于 Lasso 方法。这表明 SCAD 方法在变量选择的效果上总是优于 Lasso 方法。

从以上模拟来看, 对于带可加扭曲测量误差的高维线性模型的变量选择和参数估计问题, 本章提出的两种方法都能有效地解决此类问题, 但 SCAD 方法有着更优的性能。

5.5 实例分析

本节将性能更优的方法应用在 Boston housing 数据上, 该数据中包含的变量信息可以参考4.5.1小节。许多统计研究者都将此数据用于有关扭曲测量误差的研究中, 如 Zhang 等人^[18] 以及 Zhang 等人^[51] 的研究。在 Sentürk 和 Müller^[52] 的研究中, 发现 LSTAT 可能是一个会影响其他变量的混杂变量, 当考虑它时, CRIM 对房价也有着重要作用。此外, Zhang 等人^[51] 以及 Li 等人^[36] 也将 LSTAT 当作

表 5-1 带可加扭曲测量误差的高维线性模型的模拟结果

(n, p_n, τ)	方法	C	IC	SE
(100,200,0.1)	Oracle	3.00	0.00	0.021
	Lasso	3.00	4.69	0.484
	SCAD	3.00	2.56	0.425
	LQA-SCAD	3.00	31.69	0.426
(100,200,0.5)	Oracle	3.00	0.19	0.100
	Lasso	3.00	5.39	0.512
	SCAD	3.00	2.79	0.448
	LQA-SCAD	3.00	36.52	0.449
(100,200,1)	Oracle	3.00	3.16	0.255
	Lasso	3.00	7.29	0.609
	SCAD	3.00	6.21	0.530
	LQA-SCAD	3.00	51.08	0.531
(150,300,0.1)	Oracle	3.00	0.00	0.012
	Lasso	3.00	5.45	0.464
	SCAD	3.00	2.24	0.413
	LQA-SCAD	3.00	9.59	0.414
(150,300,0.5)	Oracle	3.00	0.35	0.063
	Lasso	3.00	6.79	0.493
	SCAD	3.00	3.91	0.431
	LQA-SCAD	3.00	12.44	0.432
(150,300,1)	Oracle	3.00	1.86	0.154
	Lasso	3.00	6.71	0.539
	SCAD	3.00	4.86	0.472
	LQA-SCAD	3.00	16.78	0.473
(200,400,0.1)	Oracle	3.00	0.00	0.012
	Lasso	3.00	6.05	0.446
	SCAD	3.00	1.38	0.402
	LQA-SCAD	3.00	3.24	0.402
(200,400,0.5)	Oracle	3.00	0.07	0.059
	Lasso	3.00	6.30	0.462
	SCAD	3.00	2.97	0.413
	LQA-SCAD	3.00	4.85	0.413
(200,400,1)	Oracle	3.00	0.35	0.063
	Lasso	3.00	7.76	0.526
	SCAD	3.00	4.92	0.467
	LQA-SCAD	3.00	7.81	0.468

表 5-2 带可加扭曲测量误差的高维线性模型的参数估计值


参数	方法		
	LQA-SCAD	SCAD	Lasso
β_1	0.9765	0.9763	0.8567
β_2	0.8067	0.8058	0.7644
β_3	0.7684	0.7657	0.7269
β_4	-0.0644	-0.0618	
β_{89}	0.0008		
β_{101}	0.0004		
β_{14}	0.0002		
β_{157}	0.0002		
β_{192}	-0.0124	-0.0124	-0.0072
β_{209}	0.0001		
β_{260}	0.0001		
β_{264}	0.0012		0.0016
β_{389}	-0.0001		

混杂变量来分析该数据。因此，我们在本节中同样将 LSTAT 视为混杂变量，除了 AGE、CHAS 和 ZN 外，所有的变量都通过混杂变量进行了调整。


对 Boston housing 数据进行中心化和标准化之后，采用 5.2.2 小节中与 SCAD 惩罚函数结合的方法进行变量选择和参数估计，窗宽按照 5.2.3 中的方法选择，使用五折交叉验证选择调优参数 λ 。此外，还计算了非零参数估计量的标准误差。表 5-3 展示了各个参数的估计值以及相关的标准误差。很容易看出，SCAD 方法选择了简单的模型，该方法在选择变量和同时估计参数方面有着独特的吸引力。

表 5-3 Boston housing 数据集在提出方法下的估计值


变量	线性回归	SCAD
RM	0.4678(0.0297)	0.5623(0.0341)
AGE	-0.1406(0.0419)	-0.0236(0.0480)
DIS	-0.3560(0.0503)	0(-)
RAD	0.2666(0.0692)	0(-)
TAX	-0.2151(0.0760)	-0.0068(0.0870)
PTRATIO	-0.2387(0.0339)	-0.1445(0.0395)
B	0.1352(0.0290)	0.0656(0.0333)
CRIM	-0.1496(0.0335)	-0.0386(0.0384)
ZN	0.0986(0.0383)	0(-)
INDUS	-0.0208(0.0504)	0(-)
CHAS	0.0888(0.0262)	0.0013(0.0300)
NOX	-0.2581(0.0529)	0(-)




(a) $\tau = 0.2$ 时的 100 次 IC 模拟结果




(b) $\tau = 0.2$ 时的 100 次 SE 模拟结果




(c) $\tau = 0.5$ 时的 100 次 IC 模拟结果



(d) $\tau = 0.5$ 时的 100 次 SE 模拟结果



(e) $\tau = 1$ 时的 100 次 IC 模拟结果



(f) $\tau = 1$ 时的 100 次 SE 模拟结果

图 5-1 $(n, p_n) = (200, 400)$ 的 100 次模拟结果

第6章 总结与展望

6.1 总结

一方面,随着科技越来越发达,所收集到的数据也越来越庞大,越来越呈现为高维数据,只有有效地利用重要变量建立的模型才会使得模型结果更加精准,进而得到更加合理的结论。另一方面,在实际问题中,由于一些主观和客观因素,使得变量存在测量误差的现象十分普遍,如若忽略测量误差的影响,则会对模型造成十分巨大的影响。因此,本文主要对带测量误差的高维线性模型的变量选择和参数估计进行研究。全文总共分为六章,以第二、三、四、五章为主要内容。

第二章介绍了线性回归模型。分别介绍了多元线性回归模型、高维线性回归模型,以及经典线性回归模型的基本假设。

第三章主要介绍了 Classical 测量误差和扭曲测量误差,以及相应的处理方法。对于 Classical 测量误差,详细地介绍了本文主要考虑的 Classical 可加测量误差模型,并以例子的形式说明了测量误差对线性模型的影响,同时也从理论的角度证明了使用最小二乘法得到的模型参数估计是有偏差的,因此需要消除测量误差对回归模型造成的影响。随后,介绍了解决测量误差问题的常用方法—工具变量法。对于扭曲测量误差,同样介绍了本文主要考虑的可加扭曲测量误差模型,并给出相应例子来说明扭曲测量误差对线性回归模型的影响,以及处理扭曲测量误差的常用方法—核密度估计法。

第四章介绍了带 Classical 可加测量误差的高维线性模型的变量选择和参数估计方法。首先,在高维线性模型下考虑 Classical 可加测量误差,建立了相关模型。其次,对 Lasso 及其优缺点进行了简单地介绍,并采用 Lasso 惩罚最小二乘法和无偏估计量构建了求解模型参数的目标函数,由于该目标函数通常是非凸函数,因此提出了基于 F 范数寻找最近正定矩阵的方法,即将非凸目标函数转换为凸函数;此外,对 SCAD 惩罚函数及其与 Lasso 的相同和不同之处进行了介绍,并将 SCAD 惩罚函数与此方法进行了结合,构建了相应的目标函数。最后,使用坐标下降法分别对上述两种方法的目标函数进行求解,并推导了相应参数估计的理论性质。为了说明方法的有效性,利用 Monte Carlo 数值模拟对比不同方法的估计效果,同时也给出了不同测量误差情形下的变量选择及参数估计结果。同时,还用与 SCAD 惩罚函数结合的方法分析了 Boston housing 数据集和利尿剂抵抗数据集。

第五章介绍了带可加扭曲测量误差的高维线性模型的变量选择和参数估计方法。之所以考虑扭曲测量误差，是因为它对测量误差的分布不做假设，相应的研究方法也不会依赖测量误差的任何分布假设，能够扩展模型方法的应用。首先，使用核密度估计法对扭曲函数的分布进行估计，从而恢复了不能被直接观测得到的预测变量和响应变量。基于恢复后的数据，分别采用 Lasso 和 SCAD 惩罚最小二乘法构建目标函数。其次，借助坐标下降法分别对两种方法的目标函数进行了求解。最后，进行了 Monte Carlo 数值模拟，结果表明所提出的方法的有效性，且与 SCAD 惩罚函数结合的方法有着更优的性能。同时，还将性能更优的方法应用在 Boston housing 数据实例分析中。

因此，对于带测量误差的高维线性模型的变量选择和参数估计问题，可以参考本文所提出的方法。

6.2 展望

目前对测量误差的研究大多是基于同质测量误差，而随着科学技术的不断完善以及科学研究的不断深入，使得测量误差可能存在异方差的情况；其次，近年来有许多惩罚函数得到不断地优化和提升，在不同的情形下有着不同的优势，如 Adaptive Lasso, Group Lasso 等，而本文仅考虑了 Lasso 和 SCAD 惩罚函数；此外，对于数据包含异常值或重尾误差时，本文所使用的惩罚最小二乘法会产生较大的偏差。因此，未来还可以有针对性的从以下几个角度继续研究：

- (1) 带异方差测量误差的高维线性模型的变量选择和参数估计；
- (2) 考虑与 Adaptive Lasso, Group Lasso 等其它惩罚函数结合的方法；
- (3) 针对数据包含异常值或者重尾误差时，鲁棒性方法的研究。

参考文献

- [1] MacMahon S, Peto R, Collins R, et al. Blood pressure, stroke, and coronary heart disease: part 1, prolonged differences in blood pressure: prospective observational studies corrected for the regression dilution bias [J]. *The Lancet*, 1990, 335 (8692): 765–774.
- [2] Lin X, Carroll R J. Nonparametric function estimation for clustered data when the predictor is measured without/with error [J]. *Journal of the American Statistical Association*, 2000, 95 (450): 520–534.
- [3] Liang H, Wang S, Carroll R J. Partially linear models with missing response variables and error-prone covariates [J]. *Biometrika*, 2007, 94 (1): 185–198.
- [4] Stefanski L, Buzas J. Instrumental variable estimation in binary regression measurement error models [J]. *Journal of the American Statistical Association*, 1995, 90 (430): 541–550.
- [5] Adcock R J. Note on the method of least squares [J]. *Analyst*, 1877, 4: 183–184.
- [6] Adcock R J. A problem in least squares [J]. *Analyst*, 1878, 5: 53–54.
- [7] Kendall M G, Stuart A. *The advanced theory of statistics*, 3rd Edition [M]. London: Griffin, 1975.
- [8] Fuller W A. *Measurement Error Models* [M]. New York: John Wiley & Sons, Inc, 1987.
- [9] Brown M L. Robust Line Estimation with Error in Both Variables [J]. *Journal of the American Statistical Association*, 1982, 77 (377): 71–79.
- [10] Cook J R, Stefanski L A. Simulation-extrapolation: the measurement error jackknife [J]. *Journal of the American Statistical Association*, 1995, 90: 1247–1256.
- [11] Wang N, Lin X, Guttierrez R. A bias Correction Regression Calibration Approach in Generalized Linear Mixed Measurement Error Model [J]. *Communications in Statistics-Theory and Methods*, 1999, 28 (1): 217–232.
- [12] Thoresen M, Laake P. Instrumental Variable Estimation in Logistic Measurement Error Models by Means of Factor Scores [J]. *Journal of the American Statistical Association*, 1999, 28 (2): 297–313.
- [13] Abarin T, Wang L. Instrumental variable approach to covariate measurement error in generalized linear models [J]. *Annals of the Institute of Statistical Mathematics*, 2012, 64: 475–493.
- [14] 关静, 陈永沛. 基于线性回归变量误差模型的工具变量法与校正似然法的比较 [J]. *统计与决策*, 2017, No.478 (81-84).

- [15] Küchenhoff H, Bender R, Langner I. Effect of Berkson measurement error on parameter estimates in Cox regression models [J]. *Lifetime Data Analysis*, 2007, 13 (2): 261–272.
- [16] Yin Z, Gao W, Tang M L, et al. Estimation of nonparametric regression models with a mixture of Berkson and classical errors [J]. *Statistics & Probability Letters*, 2013, 83 (4): 1151–1162.
- [17] Tapsoba J D, Lee S M, Wang C Y. Expected estimating equation using calibration data for generalized linear models with a mixture of Berkson and classical errors in covariates [J]. *Statistics in Medicine*, 2014, 33 (4): 675–692.
- [18] Zhang J, Chen Q, Zhou N. Correlation analysis with additive distortion measurement errors [J]. *Journal of Statistical Computation and Simulation*, 2017, 87 (4): 664–688.
- [19] Feng Z, Zhang J, Chen Q. Statistical inference for linear regression models with additive distortion measurement errors [J]. *Statistical Papers*, 2020, 61: 2483–2509.
- [20] Zhang J. Estimation and variable selection for partial linear single-index distortion measurement errors models [J]. *Statistical Papers*, 2021, 62 (2): 887–913.
- [21] Zhang J, Li G, Yang Y. Modal linear regression models with multiplicative distortion measurement errors [J]. *Statistical Analysis and Data Mining: The ASA Data Science Journal*, 2022, 15 (1): 15–42.
- [22] Tibshirani R. Regression shrinkage and selection via the lasso [J]. *Journal of the Royal Statistical Society: Series B (Methodological)*, 1996, 58 (1): 267–288.
- [23] Zou H. The adaptive lasso and its oracle properties [J]. *Journal of the American Statistical Association*, 2006, 101 (476): 1418–1429.
- [24] Fan J, Li R. Variable selection via nonconcave penalized likelihood and its oracle properties [J]. *Journal of the American Statistical Association*, 2001, 96 (456): 1348–1360.
- [25] Zhang C. Nearly unbiased variable selection under minimax concave penalty [J]. *The Annals of Statistics*, 2010, 38 (2): 894–942.
- [26] Yuan M, Lin Y. Model selection and estimation in regression with grouped variables [J]. *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, 2006, 68 (1): 49–67.
- [27] Zou H, Hastie T. Regularization and variable selection via the elastic net [J]. *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, 2005, 67 (2): 301–320.
- [28] Candès E, Tao T. The Dantzig selector: Statistical estimation when p is much larger than n [J]. *The Annals of Statistics*, 2007, 35 (6): 2313–2351.
- [29] Fan J, Lv J. A selective overview of variable selection in high dimensional feature space [J]. *Statistica Sinica*, 2010, 20 (1): 101–148.

- [30] Sørensen Ø, Frigessi A, Thoresen M. Measurement error in Lasso: Impact and likelihood bias correction [J]. *Statistica sinica*, 2015, 25 (2): 809–829.
- [31] Rosenbaum M, Tsybakov A B. Sparse recovery under matrix uncertainty [J]. *The Annals of Statistics*, 2010, 38 (5): 2620–2651.
- [32] Rosenbaum M, Tsybakov A B, et al. Improved matrix uncertainty selector [C]. In Banerjee M, eds. *From Probability to Statistics and Back: High-Dimensional Models and Processes—A Festschrift in Honor of Jon A. Wellner*, 2013: 276–290.
- [33] Loh P L, Wainwright M J. High-dimensional regression with noisy and missing data: Provable guarantees with non-convexity [J]. *Advances in Neural Information Processing Systems*, 2011, 24.
- [34] Datta A, Zou H. Cocolasso for high-dimensional error-in-variables regression [J]. *The Annals of Statistics*, 2017, 45 (6): 2400–2426.
- [35] Tao T, Pan S, Bi S. Calibrated zero-norm regularized LS estimator for high-dimensional error-in-variables regression [J]. *Statistica Sinica*, 2021, 31 (2): 909–933.
- [36] Li X, Du J, Li G, et al. Variable selection for covariate adjusted regression model [J]. *Journal of Systems Science and Complexity*, 2014, 27 (6): 1227–1246.
- [37] Rosenblatt M. Remarks on some nonparametric estimates of a density function [J]. *The Annals of Mathematical Statistics*, 1956: 832–837.
- [38] Parzen E. On estimation of a probability density function and mode [J]. *The Annals of Mathematical Statistics*, 1962, 33 (3): 1065–1076.
- [39] Donoho D L, Johnstone I M. Ideal spatial adaptation by wavelet shrinkage [J]. *Biometrika*, 1994, 81 (3): 425–455.
- [40] Breheny P, Huang J. Coordinate descent algorithms for nonconvex penalized regression, with applications to biological feature selection [J]. *The Annals of Applied Statistics*, 2011, 5 (1): 232.
- [41] Bickel P J, Ritov Y, Tsybakov A B. Simultaneous analysis of Lasso and Dantzig selector [J]. *The Annals of Statistics*, 2009, 37 (4): 1705–1732.
- [42] Wainwright M J. Sharp Thresholds for High-Dimensional and Noisy Sparsity Recovery Using ℓ_1 -Constrained Quadratic Programming (Lasso) [J]. *IEEE Transactions on Information Theory*, 2009, 55 (5): 2183–2202.
- [43] Mai Q, Zou H, Yuan M. A direct approach to sparse discriminant analysis in ultra-high dimensions [J]. *Biometrika*, 2012, 99 (1): 29–42.
- [44] Xu Q, You J. Covariate selection for linear errors-in-variables regression models [J]. *Communications in Statistics—Theory and Methods*, 2007, 36 (2): 375–386.
- [45] Harrison Jr D, Rubinfeld D L. Hedonic housing prices and the demand for clean air [J]. *Journal of Environmental Economics and Management*, 1978, 5 (1): 81–102.

- [46] 李锋, 盖玉洁, 卢一强. 测量误差模型的自适应 LASSO 变量选择方法研究 [J]. 中国科学: 数学, 2014 (9): 24.
- [47] Cui X, Guo W, Lin L, et al. Covariate-adjusted nonlinear regression [J]. The Annals of Statistics, 2009, 37 (4): 1839–1870.
- [48] 冯盼盼. 协变量调整变系数模型的模型诊断与变量选择 [D]. 郑州: 郑州大学数学与统计学院, 2018.
- [49] Jin Z, Lin D, Wei L, et al. Rank-based inference for the accelerated failure time model [J]. Biometrika, 2003, 90 (2): 341–353.
- [50] Xu J, Leng C, Ying Z. Rank-based variable selection with censored data [J]. Statistics and Computing, 2010, 20 (2): 165.
- [51] Zhang J, Zhu L P, Zhu L X. On a dimension reduction regression with covariate adjustment [J]. Journal of Multivariate Analysis, 2012, 104 (1): 39–55.
- [52] Şentürk D, Müller H-g. Covariate adjusted correlation analysis via varying coefficient models [J]. Scandinavian Journal of Statistics, 2005, 32 (3): 365–383.